UNIVERSIDAD ALFONSO X EL SABIO

Business Tech

Máster Universitario en Inteligencia Artificial

TRABAJO DE FIN DE MÁSTER

Fiabilidad de los Informes Radiológicos Generados por Modelos Multimodales: Explicabilidad Visual frente a Incertidumbre de la Decisión

Autor: Daniel Gómez Arranz

Tutor: José Antonio Marcos García

Septiembre 2026

Agradecimientos

A mi tutor, José Antonio Marcos García, por su orientación durante el desarrollo de este trabajo.

A la Universidad Alfonso X el Sabio y al profesorado del Máster Universitario en Inteligencia Artificial, por la formación recibida a lo largo de este curso.

A mi familia y amigos, por su apoyo durante estos meses de trabajo.

A mi pareja, cuyas conversaciones sobre su experiencia en el grado de Imagen para el Diagnóstico y Medicina Nuclear fueron el origen de este proyecto: gracias por acompañarme durante todo el proceso y por permitirme explorar un ámbito de aplicación de la Inteligencia Artificial con el que no estaba familiarizado.

Resumen

La generación automática de informes de radiografía de tórax mediante modelos multimodales de lenguaje (MLLM) es prometedora, pero su fiabilidad y la fidelidad de sus explicaciones visuales están poco estudiadas, lo que limita su adopción clínica. Este trabajo evalúa si la explicación visual de estos modelos (o su propia incertidumbre) permite estimar la fiabilidad de cada informe. Se implementa un marco de explicabilidad y se valida el anclaje de la atención de forma objetiva contra las cajas delimitadoras reales de NIH ChestX-ray8. El estudio de fiabilidad se articula como un diseño 2×2 que cruza dos generadores del estado del arte (LLaVA-Rad y MAIRA-2) con dos dominios (Open-I, Estados Unidos; y PadChest-GR, España), etiquetando cada informe como correcto, alucinación u omisión mediante tres fuentes de verdad independientes (diagnóstico estructurado MeSH, hallazgos presentes/ausentes de radiólogo y juez basado en modelo de lenguaje). Los resultados muestran que la atención está clínicamente anclada (lift global 3,03), pero la morfología de la explicación no predice la fiabilidad. Este resultado se confirma incluso con las cajas de anclaje entrenadas del propio modelo, que localiza sus alucinaciones de forma plausible. En cambio, la incertidumbre de la decisión, medida como la probabilidad mínima de contenido, detecta las alucinaciones con AUC 0,90 (Open-I) y se transfiere de forma robusta a otro modelo y a otro dominio (AUC 0,80–0,81), salvo en un generador débil fuera de distribución. La señal es asimétrica: detecta las fabricaciones, pero no las omisiones, que son errores confiados de sensibilidad. Una vez calibrada, la señal se traduce en una confianza por informe con bandas de riesgo ("semáforo") y en una demostración interactiva que integra informe, anclaje y confianza. El hallazgo más relevante del trabajo es que, en los modelos y dominios evaluados, la detección de alucinaciones mediante incertidumbre generativa resulta una señal de fiabilidad más útil que la morfología de la explicación visual: es cuantificable, se transfiere entre modelos y dominios, y es apta para el cribado clínico.

Palabras clave: informes radiológicos, modelos multimodales, explicabilidad, de-

tección de alucinaciones, incertidumbre.

Abstract

Automatic chest X-ray report generation with multimodal large language models (MLLM) is promising, but the reliability of these models and the faithfulness of their visual explanations remain understudied, hindering clinical adoption. This work assesses whether a model's visual explanation (or its own uncertainty) can estimate the reliability of each report. An explainability framework is implemented and the grounding of the model's attention is objectively validated against the real bounding boxes of NIH ChestX-ray8. The reliability study follows a 2×2 design crossing two state-of-the-art generators (LLaVA-Rad and MAIRA-2) with two domains (Open-I, United States; and PadChest-GR, Spain), labelling each report as correct, hallucination or omission through three independent ground-truth sources (structured MeSH diagnosis, radiologist present/absent findings, and a language-model judge). Results show that attention is clinically grounded (global lift 3.03), yet the morphology of the explanation does not predict reliability. This finding is confirmed even with the model's own trained grounding boxes, which plausibly localise its hallucinations. Instead, decision uncertainty, measured as the minimum content-token probability, detects hallucinations with AUC 0.90 (Open-I) and transfers robustly across model and domain (AUC 0.80–0.81), except for a weak generator out of distribution. The signal is asymmetric: it detects fabrications but not omissions, which are confident sensitivity errors. Once calibrated, the signal yields a per-report confidence with risk bands (a "traffic light") and an interactive demo integrating report, grounding and confidence. The most relevant finding of this work is that, across the models and domains evaluated, hallucination detection via generative uncertainty is a more useful reliability signal than the morphology of the visual explanation: it is quantifiable, transfers across models and domains, and is suitable for clinical triage.

Keywords: radiology reporting, multimodal models, explainability, hallucination detection, uncertainty.

Índice general

Agradecimientos **1**

Resumen **2**

Abstract **4**

1. Introducción al Trabajo Fin de Máster **13**

1.1. Justificación del proyecto realizado 13

1.2. Presentación del proyecto y sus contenidos 14

1.3. Preguntas de investigación 16

1.4. Contribuciones 17

2. Objetivos del TFM **18**

2.1. Evolución del alcance del proyecto 18

2.2. Objetivo general 19

2.3. Objetivos específicos 19

3. Marco Teórico / Estado del Arte **20**

3.1. Generación automática de informes radiológicos 20

3.1.1. De la descripción de imágenes al informe clínico 20

3.1.2. La era de los modelos multimodales de lenguaje 21

3.1.3. El problema de la evaluación 21

3.2. Anatomía y funcionamiento de un modelo multimodal de lenguaje . . 22
3.2.1. El *transformer* y el mecanismo de atención 23
3.2.2. El codificador visual 23
3.2.3. El conector y el preentrenamiento contrastivo 23
3.2.4. El decodificador y la generación 24
3.3. Por qué abordar el problema desde la fiabilidad y la incertidumbre . . 24
3.4. Explicabilidad en modelos *transformer* 25
3.4.1. ¿Es la atención una explicación? 25
3.4.2. Métodos de atribución y agregación 25
3.4.3. Evaluación objetiva de la fidelidad 26
3.5. Incertidumbre y detección de alucinaciones 26
3.5.1. Naturaleza de las alucinaciones 26
3.5.2. Cuantificación de la incertidumbre 27
3.5.3. Auto-consistencia y calibración 27
3.6. Datos y modelos preentrenados en radiología 28
3.6.1. Conjuntos de datos 28
3.6.2. Codificadores y destilación de conocimiento 28
3.7. Síntesis y hueco de investigación 29

4. Marco Metodológico 30

4.1. Población y muestra 30
4.2. Objetivos de investigación 31
4.3. Variables intervinientes e instrumentos de evaluación 32
4.4. El marco de explicabilidad 33
4.5. Arquitectura del generador propio 34
4.6. Definición formal de las señales 35

4.7. Protocolo de etiquetado del error 36
4.8. Requisitos del sistema 36
4.9. Arquitectura de la solución 37
4.10. Casos de uso 37
4.11. Planificación y desarrollo 38
4.12. Diseño experimental 38
4.13. Métricas de evaluación 39
4.14. Método científico y control de confusores 40
4.15. Modelo de análisis de datos 41

5. Presentación de análisis, resultados y discusión 42

5.1. Análisis descriptivo de la muestra 42
5.2. El generador propio y la lección sobre las métricas 43
5.3. La atención está clínicamente anclada 44
5.4. La morfología de la explicación no predice la fiabilidad 45
5.5. La incertidumbre de la decisión detecta las alucinaciones 45
5.5.1. Ninguna señal adicional generaliza: en favor de la simplicidad 50
5.6. Disociación alucinación–omisión 51
5.7. Calibración y confianza operativa 52
5.8. Traducción clínica: la confianza como semáforo 53
5.8.1. Por qué una demostración interactiva 53
5.8.2. Un gradiente de confianza, no una alerta de error 54
5.8.3. El radiólogo como decisor y la mitigación del sesgo de automatización 55
5.9. Consideraciones éticas, legales y de sostenibilidad 56
5.10. Impacto, agentes implicados y viabilidad 56

5.11. Discusión y análisis de los resultados 57

6. Conclusiones **59**

6.1. Respuesta a las preguntas de investigación 61

6.2. Limitaciones 61

6.3. Prospectiva 62

6.4. Mejoras futuras del sistema 64

6.5. Consideraciones finales 65

Bibliografía **66**

A. Anexos: detalles de reproducibilidad **69**

A.1. Entornos de ejecución 69

A.2. Extracción de señales 69

A.3. Hiperparámetros de generación 70

A.4. Acceso a los datos y etiquetado 70

A.5. Métodos estadísticos 70

A.6. Hardware 70

B. Anexos: manual de usuario de la demostración **71**

B.1. Puesta en marcha 71

B.2. Interfaz y flujo de trabajo 71

B.3. Instalación y ejecución con Docker (paso a paso) 75

B.4. Interpretación de la salida 76

C. Anexos: organización del repositorio **77**

C.1. Estructura 77

C.2. Reproducibilidad 77

C.3. Contenerización y portabilidad 78

Índice de figuras

4.1. Arquitectura del generador propio: codificador visual, decodificador con atención cruzada mediante compuerta inicializada a cero, y las dos etapas de entrenamiento (alineamiento y generación). 35

4.2. Flujo del sistema: de la radiografía al informe con anclaje y confianza calibrada. El bloque de análisis se valida contra la verdad objetiva (MeSH, hallazgos de radiólogo, cajas de NIH). 37

5.1. Anclaje de la atención sobre NIH por patología (casos de mayor *lift*). Mapa de calor superpuesto y caja real (verde); se indica el *lift*, el acierto/fallo del veredicto y el área relativa de la caja. La atención se concentra sobre la lesión, sobre todo en hallazgos focales. 46

5.2. Anclaje sobre NIH por patología en casos de *lift* mediano. La atención sigue sobre la región de la lesión pero de forma más difusa que en los casos de la Figura 5.1. 47

5.3. Separación de clases de la probabilidad mínima de contenido (menor = más incierto) en las cuatro celdas del diseño. Verde: correcto; gris: omisión; rojo: alucinación; líneas discontinuas: medias. Las alucinaciones se concentran en la zona incierta salvo en LLaVA-Rad·PadChest (OOD). 48

5.4. Efecto de excluir el token de apertura. Barras grises: probabilidad mínima sobre todo el informe; barras verdes: sobre el contenido (sin el primer token). La mejora es sistemática en las cuatro celdas. 49

5.5. AUC de detección de alucinaciones (probabilidad mínima de contenido) en el diseño 2×2. Verde = alto. La señal es robusta salvo en el generador débil fuera de distribución. 50

5.6. Curvas ROC de detección de alucinaciones (probabilidad mínima de contenido). Tres de las cuatro celdas dominan la diagonal de azar; LLaVA-Rad·PadChest (OOD) se aproxima a ella. 51

5.7. Disociación: AUC para separar alucinaciones (rojo) y omisiones (gris) de los informes correctos, por celda. La incertidumbre detecta alucinaciones de forma robusta y omisiones solo parcialmente. 52

5.8. Calibración: tasa de alucinación observada frente a la probabilidad mínima de contenido (media por decil, datos agregados). La relación monótona fundamenta las bandas del semáforo de confianza. 53

5.9. Semáforo de confianza en gradiente. Las bandas, definidas sobre los cuartiles de la distribución de los informes correctos, se anotan con la probabilidad de alucinación observada. El verde concentra los informes fiables (baja fricción) y el rojo prioriza la revisión. 54

5.10. Salida de la demostración (MAIRA-2) con el anclaje por cajas. Izquierda: informe con una alucinación de infiltrado, con baja confianza (zona roja). Derecha: informe normal correcto, con alta confianza (zona verde). 55

B.1. Aplicación de LLaVA-Rad en ejecución sobre un caso real de Open-I. El modelo alucina una masa pulmonar inexistente (compárese con el veredicto real del radiólogo, panel superior); el semáforo lo detecta correctamente y lo sitúa en zona roja (min_prob 0,11, P(alucinación) $\approx$ 30 %). 73

B.2. Aplicación de MAIRA-2 en ejecución sobre un caso real de PadChest-GR. El modelo también alucina en este caso; el semáforo lo sitúa igualmente en zona roja (min_prob 0,12, P(alucinación) $\approx$ 14 %). El panel de anclaje muestra la imagen con las cajas propias del modelo cuando las genera. 74

Índice de tablas

3.1. Modelos multimodales de CXR relevantes. RRG = *radiology report generation*. 21

3.2. Familias de señales de incertidumbre revisadas en la literatura. Coste en inferencia: sin generaciones adicionales (bajo) o con varias muestras extra (alto). 28

4.1. Conjuntos de datos empleados y su función en el trabajo. 33

5.1. Muestra del diseño 2×2 (etiquetas objetivas/G-Eval). n = informes; alu = alucinaciones; mis = omisiones. 43

5.2. Ablación de destilación del generador propio (M0–M3): fuentes de conocimiento introducidas. 44

5.3. Anclaje objetivo sobre NIH (n = 388 hallazgos detectados). Lift = energía-en-caja / azar. 44

5.4. AUC univariante de cada señal (orientada: mayor = más probable alucinación) por conjunto. Ninguna mejora de forma consistente a la probabilidad mínima de contenido. 52

5.5. Puntos de operación sobre Open-I (verdad MeSH; puntuación de contenido). FA = falsas alarmas. 53

6.1. Resumen de las cuatro preguntas de investigación (Capítulo 1) e hipótesis asociadas (H1–H4, Sección 4.2) frente a la evidencia obtenida. 61

Capítulo 1

Introducción al Trabajo Fin de Máster

La interpretación de imágenes médicas es una de las tareas de mayor valor y, a la vez, de mayor carga asistencial dentro del sistema sanitario. La radiografía de tórax (CXR) es la prueba de imagen más solicitada del mundo, y la redacción de su informe consume una parte considerable del tiempo del radiólogo. En este contexto, la generación automática de informes mediante inteligencia artificial se presenta como una vía prometedora de asistencia. Sin embargo, para que un sistema de este tipo sea aceptable en la práctica clínica no basta con que produzca un texto plausible: debe ser posible saber *cuándo fiarse* de él y *por qué* concluye lo que concluye. Aunque existen numerosos trabajos sobre generación de informes y sobre explicabilidad visual en modelos multimodales, sigue sin estar claro si esas explicaciones permiten estimar la fiabilidad real de cada informe generado; este trabajo se sitúa precisamente en ese vacío. Este capítulo introduce la motivación del trabajo, el problema que aborda y la organización de la memoria.

1.1 Justificación del proyecto realizado

Mi pareja se encontraba realizando un grado de Imagen para el Diagnóstico y Medicina Nuclear, y debido a esto tuve la oportunidad de hablar con algunos de los profesores del centro sobre cómo la tecnología y, en concreto, la inteligencia artificial estaban teniendo un impacto importante en la profesión. De ahí, la conversación derivó a los principales problemas que tenían con ella (sobre todo la generativa, no la clasificadora clásica, que lleva muchísimo tiempo en la industria y va por una rama completamente distinta a la que usa VLMs), y el tema que más se repetía

era la falta de explicabilidad, lo "caja negra" que es, que impide a los radiólogos comprender el porqué del diagnóstico, ya que, a diferencia de los modelos clasificadores, que simplemente clasifican una patología (de manera correcta o incorrecta), los VLMs dan una explicación de lo que ven en la imagen para apoyar el diagnóstico, pero, muchas veces, esto resulta en alucinaciones, que producen el efecto contrario al que se quiere generar: en este caso, agilizar y facilitar el diagnóstico mediante estas radiografías, que, al tener estas "alucinaciones", o errores de interpretación, hacen que se dedique más tiempo a la revisión. Esto hizo que mi planteamiento inicial fuese intentar encontrar una manera de "explicar" el diagnóstico del modelo mediante mapas de calor que interpretasen la "atención" del modelo hacia distintas zonas de la imagen. Si bien, por las propias circunstancias del proyecto, se acabó derivando gran parte del esfuerzo a otras áreas, la intención seguía siendo la misma: facilitar la comprensión y aumentar la confianza de los profesionales sanitarios en los VLMs mediante explicabilidad. Esa inquietud, nacida de una conversación ajena a la investigación académica, resultó coherente con una pregunta que la literatura científica tampoco había resuelto de forma satisfactoria (Capítulo 3): si la explicación visual de un modelo multimodal es, en la práctica, una señal fiable de cuándo confiar en su salida.

Desde el punto de vista de su utilidad, el proyecto se sitúa en la intersección de tres necesidades actuales. En el ámbito clínico, la presión asistencial y la escasez de radiólogos hacen atractiva cualquier herramienta que agilice el flujo de trabajo sin comprometer la seguridad del paciente. En el ámbito científico-técnico, los modelos multimodales de lenguaje (MLLM) han alcanzado una notable competencia en tareas de imagen y texto, pero su aplicación a dominios de alta responsabilidad exige garantías de fiabilidad y trazabilidad de las que todavía carecen. Y en el ámbito ético y regulatorio, la interpretabilidad de los sistemas de IA en salud no es una característica opcional sino un requisito: un modelo cuyas decisiones no pueden auditarse difícilmente será adoptado. El presente trabajo se orienta a este espacio, estudiando no solo la generación de informes sino, sobre todo, la fidelidad y el anclaje clínico de sus explicaciones y la posibilidad de estimar la confianza en cada informe generado.

1.2 Presentación del proyecto y sus contenidos

El problema que se aborda puede enunciarse de forma simple: un sistema que genera informes radiológicos produce, para cada afirmación, una explicación visual (un mapa de calor que señala la región de la imagen que la motivó); la cuestión es si

esa explicación es *fiel* al razonamiento del modelo, si está *anclada* a la anatomía correcta y, en última instancia, si permite detectar cuándo el modelo se equivoca.

Considérese, a modo de ilustración, un sistema que informa "cardiomegalia" sobre una radiografía de tórax normal. Si junto al texto se muestra un mapa de calor razonablemente centrado sobre la silueta cardíaca, el radiólogo dispone de una pista de *dónde* ha mirado el modelo, pero no de ninguna garantía de que ese mismo patrón de atención no acompañe también a sus aciertos: una explicación visualmente plausible puede convivir con un contenido incorrecto. La pregunta que articula el trabajo es, precisamente, si existe alguna señal (en la propia explicación o en la confianza interna del modelo) capaz de distinguir este caso del de un informe verdaderamente correcto, antes de que el error llegue al informe final.

Para responderla, el trabajo contribuye en cuatro frentes. En primer lugar, se desarrolla un generador propio encoder–decoder multimodal, en el que la restricción de datos se convierte en una decisión metodológica mediante la destilación de conocimiento desde modelos preentrenados libres. En segundo lugar, se construye un marco de explicabilidad que evalúa dos ejes: la fidelidad de las explicaciones y su anclaje clínico. En tercer lugar, dado que un modelo de escala reducida limita el alcance del análisis, se eleva el estudio a un MLLM del estado del arte (LLaVA-Rad) y se valida su anclaje de forma objetiva contra anotaciones reales de localización. Por último, se investiga si la explicación, o la propia incertidumbre del modelo, permite detectar alucinaciones, y se comprueba que la señal de confianza resultante es agnóstica al modelo y robusta al dominio mediante una réplica en un segundo generador (MAIRA-2) y un segundo dominio (PadChest-GR); la señal se calibra como una confianza por informe y se materializa en una demostración interactiva que integra informe, anclaje y fiabilidad.

El interés del problema se ha intensificado con la irrupción de los modelos multimodales de lenguaje (MLLM), que acoplan un potente codificador visual a un modelo de lenguaje de gran tamaño y han elevado de forma notable la calidad del texto generado a partir de imágenes. Su aplicación a la radiografía de tórax promete asistir en la redacción del informe, agilizando el flujo de trabajo. Sin embargo, esta misma potencia trae consigo un riesgo característico: la alucinación, es decir, la generación de afirmaciones plausibles pero no sustentadas por la imagen. En un dominio de alta responsabilidad como el diagnóstico por imagen, una alucinación no detectada puede tener consecuencias graves, y una omisión (no reportar un hallazgo presente) otras distintas pero igualmente serias. Por ello, el problema no es solo generar buen texto, sino saber cuándo el texto generado es fiable, y hacerlo de una forma que el clínico pueda interpretar y en la que pueda confiar. Es en esta intersección, entre la

capacidad generativa de los MLLM y la exigencia de fiabilidad y transparencia del entorno clínico, donde se inscribe el presente trabajo.

1.3 Preguntas de investigación

El problema anterior se concreta en cuatro preguntas de investigación que vertebran el trabajo:

- **PI1.** ¿Está la atención de un MLLM de radiografía de tórax *anclada* sobre la región anatómica de la lesión, contrastada con anotaciones objetivas de localización?
- **PI2.** ¿Permite la *morfología* de la explicación (la forma del mapa de calor, o las cajas de anclaje del propio modelo) detectar cuándo el modelo se equivoca?
- **PI3.** ¿Permite la *incertidumbre* de la decisión del modelo detectar sus errores, y con qué asimetría entre alucinaciones y omisiones?
- **PI4.** ¿Es esa señal de fiabilidad *agnóstica al modelo y robusta al dominio*, es decir, se transfiere a otro generador y a otra población?

1.4 Contribuciones

Las principales contribuciones del trabajo son las siguientes. Primera, una auditoría objetiva del anclaje de la atención de un MLLM de CXR frente a cajas delimitadoras reales. Segunda, la constatación (por triple vía, incluida la de las cajas entrenadas del propio modelo) de que la morfología de la explicación no predice la fiabilidad, así como la identificación de varios *artefactos* metodológicos que solo un control cuidadoso de confusores reveló. Tercera, la disociación entre errores detectables por incertidumbre (alucinaciones) y errores confiados (omisiones), y la propuesta de una señal de confianza simple, agnóstica y disponible en inferencia. Cuarta, una validación cruzada de dicha señal en un diseño de dos generadores por dos dominios, que demuestra su robustez. Y quinta, su calibración y su traducción en una demostración interactiva que integra informe, anclaje y confianza para el clínico. Como aportación metodológica menor, se documenta que *excluir el token de apertura del informe* mejora de forma sistemática la señal de incertidumbre.

La memoria se organiza como sigue. El Capítulo 2 fija el objetivo general y los específicos, y explica cómo evolucionó el alcance del proyecto hasta llegar a ellos. El Capítulo 3 revisa el estado del arte en cuatro frentes: generación automática de informes, funcionamiento interno de los modelos multimodales, explicabilidad de *transformers* y detección de incertidumbre y alucinaciones. El Capítulo 4 describe en detalle la metodología: la población y la muestra, las hipótesis, las variables y los instrumentos de medida, la arquitectura del generador propio y el diseño experimental. El Capítulo 5 presenta los resultados siguiendo el orden en que se han enunciado las preguntas de investigación, y los discute a la luz de la literatura y de sus implicaciones prácticas. El Capítulo 6, por último, recoge las conclusiones, valora las limitaciones (incluidas las derivadas de las condiciones materiales del proyecto) y traza las líneas futuras, tanto de investigación como de mejora del sistema.

Capítulo 2

Objetivos del TFM

En este capítulo se establece el objetivo general del trabajo y los objetivos específicos en que se desglosa. Los objetivos se redactan en infinitivo y se corresponden con metas concretas alcanzadas al término del proyecto: uno asociado al marco teórico, otro al desarrollo metodológico y los restantes a la validación empírica.

2.1 Evolución del alcance del proyecto

El planteamiento inicial situaba la explicabilidad visual (la morfología del mapa de calor de atención) como la señal candidata para estimar la fiabilidad de un informe. La evidencia recabada en las primeras fases del trabajo (Capítulo 5, PI2) mostró que dicha morfología no discrimina entre aciertos y errores, lo que exigió una reformulación del alcance: el foco se desplazó a la incertidumbre de la decisión como señal alternativa, y el diseño experimental se amplió a una validación cruzada 2×2 (dos generadores por dos dominios) para descartar que el resultado negativo de la explicabilidad fuese un artefacto de un único modelo o población. El propio orden de trabajo responde a una decisión deliberada: se optó por construir primero un generador propio, más pequeño y con destilación de conocimiento, precisamente para entender *desde dentro* el funcionamiento de estos sistemas y las limitaciones específicas de un modelo de menor capacidad, antes de dar el salto a un modelo del estado del arte ya entrenado y tratado como caja cerrada. Esa fase reveló, entre otras lecciones, que las métricas de solapamiento léxico como ROUGE son inadecuadas para valorar el equilibrio entre acierto y alucinación (Sección 5.2), lo que motivó abandonarlas en favor de la corrección clínica. Junto con la combinación de cómputo en hardware de consumo y el acceso restringido a los grandes corpus clínicos (Sección 4.1), estas lecciones llevaron a elevar el análisis de explicabilidad a

un modelo del estado del arte (LLaVA-Rad, y después MAIRA-2), ejecutados localmente mediante cuantización en lugar de entrenados desde cero. Los objetivos que siguen recogen ya el alcance resultante de esta reformulación, no el planteamiento original.

2.2 Objetivo general

Investigar qué señales internas de los modelos multimodales de lenguaje permiten estimar de forma fiable la corrección de los informes radiológicos generados automáticamente, comparando el valor de la explicabilidad visual y de la incertidumbre generativa como mecanismos de detección de errores y estimación de confianza.

2.3 Objetivos específicos

1. Analizar el estado del arte en generación automática de informes radiológicos, en explicabilidad de modelos transformer y en detección de incertidumbre y alucinaciones, identificando el hueco que este trabajo aborda.
2. Diseñar e implementar un sistema de generación de informes encoder–decoder multimodal, incorporando destilación de conocimiento desde modelos preentrenados libres como respuesta metodológica a la restricción de datos.
3. Construir un marco reutilizable de explicabilidad que permita extraer y evaluar, de forma sistemática, las explicaciones visuales de un generador de informes.
4. Cuantificar de forma objetiva el anclaje clínico de la atención de un modelo multimodal del estado del arte, contrastándola con anotaciones reales de localización (bounding boxes de NIH ChestX-ray8).
5. Determinar si la explicabilidad y la incertidumbre del modelo permiten detectar sus errores (alucinaciones y omisiones), sentando las bases de una estimación de confianza por informe, agnóstica al modelo empleado.

Capítulo 3

Marco Teórico / Estado del Arte

Este capítulo revisa el conocimiento científico relevante para el trabajo, organizado en cuatro áreas: la generación automática de informes radiológicos, la explicabilidad de los modelos *transformer*, la estimación de incertidumbre y la detección de alucinaciones en modelos generativos, y los conjuntos de datos y modelos preentrenados del dominio radiológico. El capítulo concluye con una síntesis que sitúa la aportación del trabajo respecto al estado del arte y delimita el hueco de investigación que se aborda.

3.1 Generación automática de informes radiológicos

3.1.1 De la descripción de imágenes al informe clínico

La generación de informes a partir de imágenes médicas hereda su formulación del *image captioning*: producir una secuencia de texto condicionada a una imagen. Las primeras aproximaciones adoptaron arquitecturas **codificador–decodificador** (Vinyals et al., 2015) en las que una red convolucional resumía la imagen en un vector de características y una red recurrente (LSTM o GRU) generaba el texto palabra a palabra. La incorporación de mecanismos de **atención visual** (Xu et al., 2015) permitió que cada palabra generada se condicionara a distintas regiones de la imagen, mejorando tanto la calidad como la interpretabilidad aparente de la salida.

El informe radiológico presenta, sin embargo, particularidades que lo distinguen de una simple descripción. Es un texto largo, estructurado y altamente estandarizado, organizado en secciones (*Findings*, *Impression*) y dominado por un lenguaje clínico repetitivo en el que la mayoría de estudios son normales. Estas características

Tabla 3.1: Modelos multimodales de CXR relevantes. RRG = *radiology report generation*.

Modelo	Base de lenguaje	Entrenamiento	Anclaje explícito
LLaVA-Rad	Vicuna-7B	MIMIC-CXR	No
MAIRA-2	Vicuna-7B	MIMIC-CXR, PadChest, USMix	Sí (cajas)
CXR-LLAVA	Llama-2-7B	Multi-corpus	No

motivaron arquitecturas específicas: modelos con memoria relacional y módulos de generación guiada por conocimiento, que buscaban capturar la estructura del informe y las correlaciones entre hallazgos, y que constituyeron el estándar antes de la irrupción de los grandes modelos.

3.1.2 La era de los modelos multimodales de lenguaje

La generalización de los *transformers* y el preentrenamiento a gran escala dieron lugar a los modelos multimodales de lenguaje (MLLM), que acoplan un codificador visual a un modelo de lenguaje de gran tamaño mediante una capa de proyección, siguiendo el paradigma de LLaVA (Liu et al., 2023). Su adaptación al dominio radiológico ha producido generadores de informes de calidad notablemente superior. Entre ellos destacan **LLaVA-Rad** (Zambrano Chaves et al., 2025), que combina un codificador biomédico con un decodificador Vicuna afinado sobre datos de tórax; y **MAIRA-2** (Bannur et al., 2024), orientado a la *generación anclada* (*grounded report generation*): además del texto, produce cajas delimitadoras que localizan cada hallazgo, entrenado sobre una combinación de corpus (MIMIC-CXR, PadChest y USMix). Otros sistemas recientes exploran el razonamiento por agentes, la integración de herramientas de detección especializadas y arquitecturas de mayor escala capaces de procesar varias imágenes o exploraciones longitudinales del mismo paciente. Estas tendencias amplían la capacidad expresiva de los MLLM de CXR, pero no resuelven por sí solas la pregunta que articula este trabajo: si esa capacidad generativa va acompañada de una forma fiable de saber cuándo confiar en cada informe individual. La Tabla 3.1 resume las características de los modelos empleados o relevantes para este trabajo.

3.1.3 El problema de la evaluación

La evaluación de estos sistemas se apoya tradicionalmente en **métricas de solapamiento léxico** heredadas del resumen automático, como ROUGE (Lin, 2004),

BLEU o METEOR, que comparan el texto generado con el informe de referencia contando n-gramas comunes. Estas métricas presentan una debilidad grave en radiología: al estar el dominio dominado por informes normales y por un lenguaje de plantilla, un modelo que memoriza la plantilla mayoritaria obtiene puntuaciones altas sin leer realmente la imagen. Este trabajo constata empíricamente el fenómeno: una variante mejor anclada a la imagen puede obtener un ROUGE inferior al de un modelo ciego que reproduce la plantilla.

Por ello, la comunidad ha desarrollado métricas de eficacia clínica que evalúan la corrección de los hallazgos y no la coincidencia superficial de palabras: clasificadores de etiquetas radiológicas que extraen los hallazgos de ambos informes y los comparan (obteniendo precisión, sensibilidad y F_1 por patología), y métricas basadas en grafos de conocimiento que contrastan las entidades clínicas y sus relaciones. Entre las primeras destacan los **clasificadores de etiquetas radiológicas** como **CheXbert** (Smit et al., 2020), que combina reglas expertas y un modelo BERT afinado para extraer de cada informe un vector de hallazgos (presente, ausente o incierto para cada patología) y calcular métricas de precisión, sensibilidad y F_1 sobre esa comparación; entre las segundas, las basadas en **grafos de conocimiento** como **RadGraph** (Jain et al., 2021), que representa las entidades clínicas de un informe (hallazgos, anatomía, atributos) y sus relaciones en un grafo estructurado, y cuya comparación entre grafo generado y grafo de referencia (*RadGraph* F_1) penaliza tanto los hallazgos inventados como los omitidos con mayor granularidad que un simple recuento de etiquetas. Estas métricas se aproximan mucho más al criterio del radiólogo que el solapamiento léxico, aunque a costa de depender de un extractor de hallazgos que introduce su propio error. Este trabajo evita esa limitación adoptando, en su lugar, fuentes de verdad ya estructuradas (MeSH, hallazgos de radiólogo) y un juez de lenguaje sobre la narrativa completa (Capítulo 4). La distinción entre *corrección clínica* y *similitud textual* es central para este trabajo, pues motiva que la fiabilidad se defina en términos de acierto sobre hallazgos significativos y no de solapamiento léxico. En consecuencia, la frontera de la investigación se ha desplazado de *generar mejor* a *saber cuándo fiarse* de lo generado: la fiabilidad y la explicabilidad.

3.2 Anatomía y funcionamiento de un modelo multimodal de lenguaje

Comprender cómo funciona internamente un MLLM es imprescindible para justificar por qué las señales empleadas en este trabajo (el mapa de calor de atención y las probabilidades de los tokens) son precisamente las que son. Esta sección describe

sus componentes.

3.2.1 El *transformer* y el mecanismo de atención

La arquitectura *transformer* (Vaswani et al., 2017) sustituyó la recurrencia por el mecanismo de **auto-atención**: cada elemento de una secuencia calcula una combinación ponderada del resto, donde los pesos, la *atención*, se obtienen de la similitud entre una *query* y unas *keys*. Formalmente, $\text{Attention}(Q, K, V) = \text{softmax}(QK^\top/\sqrt{d})V$. Este mecanismo, además de su eficacia, expone una magnitud interpretable (cuánto atiende cada token a cada otro) que está en el origen del debate sobre si la atención constituye una explicación, y que este trabajo aprovecha y, al mismo tiempo, somete a validación.

3.2.2 El codificador visual

Para procesar la imagen, los MLLM emplean un **Vision Transformer** (ViT) (Dosovitskiy et al., 2021), que divide la imagen en una rejilla de parches (por ejemplo, 16×16 o 14×14 píxeles), los proyecta linealmente en *tokens* y les aplica autoatención como si fueran palabras. El resultado es una secuencia de características por parche más un *token* global (CLS). Esta rejilla de parches es la que confiere *estructura espacial* a la atención: al promediar la atención que los tokens de texto dirigen a los tokens visuales y reordenarla en la rejilla, se obtiene el mapa de calor sobre la imagen. En los codificadores empleados en este trabajo, dicha rejilla es de 37×37 parches. Codificadores auto-supervisados de dominio, como RAD-DINO (Pérez-García et al., 2024), aprenden estas representaciones sin supervisión textual y mejoran la calidad del anclaje.

3.2.3 El conector y el preentrenamiento contrastivo

El puente entre la imagen y el modelo de lenguaje (el conector) adopta distintas formas: una simple **proyección lineal** de las características visuales al espacio del lenguaje (como en LLaVA (Liu et al., 2023)), un módulo de consulta aprendido (*Q-Former*) que resume la imagen en unos pocos tokens (BLIP-2 (Li et al., 2023)), o **atención cruzada con compuerta** intercalada en el decodificador (Flamingo (Alayrac et al., 2022)). El generador propio de este trabajo adopta esta última vía. Con frecuencia, el codificador visual se ha alineado previamente con el texto mediante un **preentrenamiento contrastivo** de tipo CLIP (Radford et al., 2021), que

aproxima en un espacio común los embeddings de imágenes y textos emparejados; la Etapa 1 del modelo propio reproduce esta idea.

3.2.4 El decodificador y la generación

Una vez inyectadas las características visuales, un modelo de lenguaje decodificador genera el informe de forma autorregresiva: en cada paso produce una distribución de probabilidad sobre el vocabulario y emite un token. Este proceso es la segunda fuente de señal que explota el trabajo: la probabilidad que el modelo asigna a cada token generado, junto con su entropía, son un subproducto directo del paso hacia adelante, disponible *sin coste adicional* en cualquier generador. El entrenamiento suele constar de una fase de alineamiento y una de *instruction tuning* visual (Liu et al., 2023), que enseña al modelo a seguir la instrucción de describir la imagen.

Consecuencia metodológica. La arquitectura anterior explica por qué las dos señales centrales del trabajo son *naturales* y *agnósticas al modelo*: la atención de los tokens de texto hacia los tokens visuales proporciona el mapa de calor (la explicación de *dónde* mira el modelo), y la distribución de probabilidad de cada token proporciona la incertidumbre (la señal de *cuánto* fiarse). Ambas se obtienen del mismo paso de inferencia que ya se ejecuta para generar el informe, sin modelos auxiliares ni cómputo extra.

3.3 Por qué abordar el problema desde la fiabilidad y la incertidumbre

La decisión de centrar el trabajo en la fiabilidad (y no en mejorar la generación) responde a un diagnóstico del estado del arte. Por un lado, la calidad del texto generado por los MLLM de CXR *se está saturando*, mientras que el verdadero cuello de botella para su adopción clínica es la confianza: la tendencia de estos modelos a alucinar sigue siendo la principal barrera (Ji et al., 2023). Por otro, existen dos grandes familias de señales de fiabilidad: las externas, que requieren un verificador adicional (un informe de referencia u otro modelo), y las intrínsecas, que se leen de la propia salida del modelo. Este trabajo prioriza las segundas por tres razones: son agnósticas al modelo (transfieren a cualquier generador), están disponibles en inferencia sin coste adicional, y capturan la información de que el propio modelo dispone sobre su acierto: en buena medida, los modelos de lenguaje "saben lo que

saben" (Kadavath et al., 2022). La cuestión abierta, que el trabajo aborda, es si esa información se lee mejor en la *forma* de la explicación visual o en la *incertidumbre* de la decisión, y si, una vez elegida, resulta **calibrable** (Guo et al., 2017) para su uso clínico.

3.4 Explicabilidad en modelos *transformer*

3.4.1 ¿Es la atención una explicación?

La explicabilidad de los *transformers* gira en gran medida en torno a si los pesos de atención constituyen una explicación válida de sus decisiones. El debate quedó planteado por Jain y Wallace (2019), que mostraron que es posible encontrar distribuciones de atención muy distintas que producen la misma predicción, cuestionando que la atención sea *fiel* al razonamiento del modelo. La réplica de Wiegreffe y Pinter (2019) matizó la conclusión: la atención sí porta información explicativa bajo ciertas condiciones y su utilidad depende de cómo se defina y evalúe una explicación. Este debate es directamente pertinente para la radiología, donde el mapa de calor de atención se ofrece con frecuencia como justificación visual del diagnóstico.

3.4.2 Métodos de atribución y agregación

Para agregar la atención a lo largo de las múltiples capas del modelo se propuso el *attention rollout* (Abnar & Zuidema, 2020), que compone las matrices de atención capa a capa teniendo en cuenta las conexiones residuales. Métodos posteriores como el de Chefer et al. (2021) combinan atención y gradientes para obtener mapas de relevancia más fieles, propagando la relevancia a través de la red de forma consistente con las reglas de conservación. En paralelo, la familia de métodos basados en gradientes produce mapas de saliencia a partir de los gradientes de la salida respecto a las activaciones intermedias: el *class activation mapping* y su generalización Grad-CAM ponderan los mapas de características por la importancia del gradiente para obtener una localización gruesa de la evidencia, mientras que los métodos de propagación de relevancia redistribuyen la puntuación de salida hacia atrás, capa a capa, hasta la entrada. Cada familia tiene ventajas e inconvenientes: los mapas de atención son baratos pero de fidelidad discutida; los basados en gradientes son más costosos y sensibles al ruido; y los de propagación exigen reglas específicas por tipo de capa. Frente a ellos, *Integrated Gradients* (Sundararajan et al., 2017) mide la contribución causal de cada entrada integrando los gradientes a lo largo de un camino

desde una referencia neutra hasta la entrada real, ofreciendo garantías axiomáticas (sensibilidad e invariancia de implementación) de las que la atención carece.

3.4.3 Evaluación objetiva de la fidelidad

La proliferación de métodos hace imprescindible evaluar objetivamente la fidelidad de una explicación, en lugar de limitarse a comparar mapas entre sí. Las métricas de perturbación (eliminación e inserción de las regiones más relevantes) y las nociones de *comprehensiveness* (cuánto cae la confianza al eliminar lo señalado como importante) y *sufficiency* (cuánta confianza se conserva reteniendo solo lo importante), formalizadas en el *benchmark* ERASER (DeYoung et al., 2020), permiten cuantificar si la explicación captura de verdad lo que impulsa la predicción. Este trabajo adopta esta filosofía: la explicación se valida frente a referencias objetivas (cajas delimitadoras reales y perturbaciones controladas) en lugar de asumir su fidelidad por inspección visual. Como advertencia transversal, Ghassemi et al. (2021) argumentan que las explicaciones locales por saliencia en salud pueden generar una **falsa sensación de confianza** y fomentar el sesgo de automatización si se presentan como garantía de fiabilidad sin validación, lo que refuerza la necesidad de distinguir entre *dónde* mira el modelo y *cuánto* debe fiarse el clínico de su veredicto.

3.5 Incertidumbre y detección de alucinaciones

3.5.1 Naturaleza de las alucinaciones

En los modelos generativos de lenguaje se denomina alucinación a la producción de afirmaciones no sustentadas por la evidencia. Los estudios de síntesis del fenómeno (Ji et al., 2023) distinguen entre alucinaciones *intrínsecas* (que contradicen la entrada) y *extrínsecas* (no verificables con ella), y las atribuyen a factores tanto de los datos (sesgos y ruido en el corpus de entrenamiento) como de la propia decodificación (la exposición a su propia salida y la tendencia a completar patrones plausibles). En la generación de informes radiológicos, esta taxonomía se concreta en dos modos de error clínicamente opuestos: la alucinación propiamente dicha, afirmar un hallazgo agudo que no está presente (falso positivo), y la omisión o *miss*, no reportar un hallazgo agudo que sí lo está (falso negativo). Ambos comprometen la seguridad del paciente de forma distinta y, como se mostrará, presentan una firma de incertidumbre radicalmente diferente, lo que constituye uno de los ejes del presente trabajo.

3.5.2 Cuantificación de la incertidumbre

La detección de alucinaciones se ha vinculado más a la incertidumbre del propio modelo que a sus explicaciones visuales. Las señales más directas son de nivel de token: la probabilidad asignada por el modelo a cada token generado y la entropía predictiva de la distribución en cada paso. La probabilidad mínima a lo largo de la secuencia (el token menos seguro) y la fracción de tokens de baja probabilidad son resúmenes habituales. Estas señales presentan, no obstante, confusores conocidos (la longitud del texto, la posición del token o su función sintáctica) que este trabajo controla explícitamente. Un refinamiento propuesto es la **entropía semántica** (Kuhn et al., 2023), que agrupa las generaciones equivalentes en significado antes de medir la incertidumbre, de modo que la variabilidad puramente léxica no infle la estimación.

3.5.3 Auto-consistencia y calibración

Una vía complementaria y agnóstica al modelo (solo requiere poder muestrear) es la **auto-consistencia**: SelfCheckGPT (Manakul et al., 2023) detecta alucinaciones sin recursos externos generando varias muestras y midiendo su acuerdo, bajo la hipótesis de que un contenido factual tiende a repetirse mientras que uno alucinado varía entre muestras. Esta idea se ha adaptado específicamente a la generación de informes radiológicos mediante métodos de tipo caja negra que muestrean varios informes y contrastan la consistencia de cada afirmación, como RadFlag (Zhang et al., 2025), que combina muestreo y un juez de lenguaje para marcar las afirmaciones poco respaldadas. El presente trabajo se relaciona con esta línea pero se diferencia de ella en que, además de la consistencia, estudia la señal de probabilidad de token (más barata, pues no exige múltiples generaciones), la caracteriza frente a las omisiones y la valida de forma cruzada entre modelos y dominios. Finalmente, para que una señal de confianza sea útil no basta con que discrimine: debe estar calibrada, es decir, que una confianza estimada del 20 % corresponda a un 20 % de aciertos observados. La calibración se evalúa con curvas de fiabilidad y con el error de calibración esperado, y se corrige con métodos como la regresión de Platt o la regresión isotónica. La literatura advierte, además, de que el ajuste por refuerzo con retroalimentación humana tiende a producir modelos sobre-confiados, lo que puede degradar precisamente las señales de probabilidad en modelos muy afinados. Estas ideas motivan que en este trabajo se evalúen la probabilidad de los tokens y la variabilidad entre muestras como señales candidatas, que se controle su calibración y que se declaren sus límites. La Tabla 3.2 resume las familias de señales revisadas y

Tabla 3.2: Familias de señales de incertidumbre revisadas en la literatura. Coste en inferencia: sin generaciones adicionales (bajo) o con varias muestras extra (alto).

Señal	Nivel	Coste	Referencia
Probabilidad de token (mín./media)	Token	Bajo	Este trabajo
Entropía predictiva	Token	Bajo	—
Entropía semántica	Secuencia	Alto (agrupa muestras)	(Kuhn et al., 2023)
Auto-consistencia (SelfCheckGPT)	Secuencia	Alto (K muestras)	(Manakul et al., 2023)
Auto-consistencia + juez (RadFlag)	Secuencia	Alto (K muestras + juez)	(Zhang et al., 2025)

su coste.

3.6 Datos y modelos preentrenados en radiología

3.6.1 Conjuntos de datos

La disponibilidad de datos condiciona fuertemente el dominio. El conjunto **NIH ChestX-ray8** (Wang et al., 2017) aporta clasificación multi-etiqueta y, de forma parcial, **localización mediante cajas delimitadoras** para ocho patologías, lo que lo hace idóneo como referencia objetiva de anclaje. **Open-I / Indiana University X-ray** (Demner-Fushman et al., 2016) es prácticamente el único conjunto de acceso libre con **informes narrativos completos** y, además, con diagnóstico estructurado (términos MeSH), lo que permite un etiquetado objetivo del error. Corpus de mayor tamaño como MIMIC-CXR ofrecen cientos de miles de informes pero requieren credenciales restringidas. **PadChest** y su subconjunto anclado **PadChest-GR** (Castro et al., 2025) aportan un dominio distinto (población española), anotaciones de hallazgos **presentes y ausentes** por radiólogo y cajas, resultando idóneos tanto como segunda fuente de verdad objetiva (independiente del juez basado en modelo de lenguaje) como para evaluar la generalización fuera de distribución.

3.6.2 Codificadores y destilación de conocimiento

La restricción de datos narrativos motiva el uso de destilación de conocimiento desde modelos preentrenados libres. En el eje textual, **CXR-BERT** (Boecking et al., 2022) es un codificador de lenguaje con semántica clínica, entrenado para alinear

texto e imagen radiológicos; en el eje visual, **RAD-DINO** (Pérez-García et al., 2024) es un codificador de imagen radiológica auto-supervisado que aprende representaciones potentes sin depender de supervisión textual, y que constituye, de hecho, el codificador visual de MAIRA-2. La destilación permite mejorar un modelo propio de escala reducida sin acceso a datos adicionales, convirtiendo la limitación de datos en una decisión metodológica deliberada. El panorama de generadores del estado del arte es, además, crecientemente diverso: junto a los modelos densos de tipo LLaVa han aparecido sistemas de *grounded reporting* que producen cajas, modelos de propósito médico general y enfoques de razonamiento por agentes que combinan varios modelos especializados. Esta diversidad refuerza el interés de disponer de una señal de fiabilidad agnóstica al generador, que pueda aplicarse a cualquiera de ellos sin depender de su arquitectura interna, como la que este trabajo propone.

3.7 Síntesis y hueco de investigación

De la revisión anterior se desprende un panorama consistente. Los MLLM de CXR del estado del arte generan texto de calidad y muestran alta especificidad, pero adolecen de dos carencias: una **sensibilidad limitada** (tienden a omitir hallazgos, con una especificidad notablemente superior a su sensibilidad ante la patología (Khovanova et al., 2025)) y, sobre todo, una ausencia de explicabilidad validada, como se ha discutido en las Secciones 3.2 y 3.4. Al mismo tiempo, la literatura de explicabilidad advierte de que las explicaciones visuales pueden ser **engañosas** si se asumen fiables sin validación (Ghassemi et al., 2021), y la literatura de incertidumbre ofrece señales prometedoras (probabilidad de token, entropía semántica, auto-consistencia) pero desarrolladas, en su mayoría, sobre modelos de lenguaje generales y sin una validación cruzada entre modelos y dominios en el ámbito radiológico. Este trabajo se sitúa precisamente en ese hueco: en lugar de proponer otro generador, audita objetivamente si la explicación de un MLLM de CXR está anclada, comprueba si su morfología permite detectar los errores, y determina dónde reside realmente la señal de fiabilidad, validándola de forma cruzada sobre dos modelos y dos dominios y traduciéndola a una confianza calibrada por informe.

Capítulo 4

Marco Metodológico

En este capítulo se describe el método seguido para desarrollar y evaluar el trabajo. Se detallan la población y la muestra empleadas, los objetivos de investigación y sus hipótesis, las variables medidas y los instrumentos de evaluación, el diseño experimental y, finalmente, el modelo de análisis de datos. El enfoque combina el desarrollo de un sistema de generación de informes con un marco de evaluación de la explicabilidad, y su validación tanto sobre un modelo propio como sobre un modelo multimodal del estado del arte.

4.1 Población y muestra

La población objeto de estudio son los estudios de radiografía de tórax (CXR) acompañados de su informe clínico. Se han utilizado dos conjuntos de datos de acceso libre, seleccionados por su disponibilidad sin restricciones frente a alternativas como MIMIC-CXR, cuyo acceso exige credenciales de PhysioNet no disponibles para este trabajo.

El conjunto principal es **Open-I / Indiana University CXR** (Demner-Fushman et al., 2016), que reúne 3.955 estudios y 7.470 imágenes (vistas frontal y lateral) con informes narrativos estructurados en secciones *FINDINGS* e *IMPRESSION*. La partición en entrenamiento, validación y prueba (70/15/15) se realiza por identificador de estudio, de modo que ambas vistas de un mismo paciente permanecen en la misma partición y se evita la fuga de información entre conjuntos.

El segundo conjunto es **NIH ChestX-ray8** (Wang et al., 2017), del que se emplean las 984 anotaciones con **caja delimitadora (bounding box)** correspondientes a

ocho patologías (atelectasia, cardiomegalia, derrame, infiltrado, masa, nódulo, neumonía y neumotórax). Estas cajas constituyen la referencia objetiva de localización que permite evaluar el anclaje clínico de la atención sin depender de un juicio subjetivo. La restricción de datos narrativos (Open-I es prácticamente el único conjunto libre con informes completos) motiva que la mejora del modelo propio se aborde mediante destilación de conocimiento desde modelos preentrenados libres, convirtiendo la limitación en una decisión metodológica.

El tercer conjunto es **PadChest-GR** (Castro et al., 2025), subconjunto anclado del corpus español PadChest, del que se emplea una muestra de estudios con **hallazgos presentes y ausentes anotados por radiólogo** y sus cajas. PadChest-GR cumple una doble función: proporciona una segunda fuente de verdad objetiva (independiente del juez basado en modelo de lenguaje) y constituye un dominio distinto (población española) respecto a Open-I (Estados Unidos), lo que permite evaluar la generalización *fuera de distribución*. El cruce de ambos dominios con dos generadores da lugar al diseño 2×2 que vertebra la validación.

En cuanto al detalle y el preprocesado, Open-I reúne 3.955 estudios y 7.470 imágenes (proyecciones frontal y lateral); su partición 70/15/15 se realiza por identificador de estudio para que ambas vistas de un paciente permanezcan juntas y no se produzca fuga de información. De NIH se emplean las 984 anotaciones con caja de ocho patologías. Del subconjunto de PadChest-GR analizado (382 estudios, de los cuales 120 son normales y 262 presentan algún hallazgo) se extraen los hallazgos presentes y ausentes anotados por radiólogo. En todos los casos, las imágenes se convierten a escala de grises de tres canales, se redimensionan a la resolución de entrada del codificador correspondiente (224 píxeles para el *Vision Transformer*, 518 para RAD-DINO) y se normalizan con las estadísticas del preentrenamiento. El texto de referencia se limpia de secciones administrativas, conservando *Findings* e *Impression*.

4.2 Objetivos de investigación

La investigación empírica se organiza en torno a tres hipótesis:

- **H1.** La atención de un modelo multimodal de CXR está *anclada clínicamente*, es decir, se concentra sobre la región anatómica de la lesión.
- **H2.** La *forma* del mapa de calor (su morfología: concentración, dispersión, etc.) permite detectar cuándo el modelo se equivoca (alucinación o error).
- **H3.** La *incertidumbre generativa* del modelo (las probabilidades de su propia

salida) permite detectar dichos errores.

- **H4.** Dicha señal de incertidumbre es *agnóstica al modelo y robusta al dominio*: se transfiere a otro generador y a otra población distinta de la de entrenamiento.

Como se mostrará, H1 se confirma y H3 se sostiene, mientras que H2 se refuta de forma robusta: la fiabilidad no reside en la morfología de la explicación sino en la incertidumbre de la decisión del modelo. H4 se confirma con un matiz relevante: la señal se transfiere entre modelos y se mantiene fuera de distribución para un generador de calidad suficiente, mientras que un generador débil la pierde fuera de distribución al recaer en un informe-plantilla emitido con confianza.

4.3 Variables intervinientes e instrumentos de evaluación

Las variables evaluadas se agrupan en tres familias. (i) *Morfología del mapa de calor*: concentración, dispersión (entropía, índice de Gini), agrupamiento y autocorrelación espacial. (ii) *Incertidumbre generativa*: probabilidad del token menos seguro (`min_prob`) y entropía predictiva por token. Una decisión de diseño relevante es emplear la probabilidad mínima de *contenido* (excluyendo el token de apertura del informe, cuya incertidumbre es de estilo y no de contenido), que mejora sustancialmente la señal (véase Cap. 5). (iii) *Dependencia de la imagen y consistencia*: fracción de atención dirigida a los tokens visuales frente al texto, persistencia del hallazgo ante una imagen en blanco (*blank_ sim*) y variabilidad entre muestras (autoconsistencia tipo SelfCheckGPT). La *blank_ sim* resulta además un indicador de la calidad del generador: cuanto más depende de la imagen (menor similitud con la salida en blanco), mejor anclado está el modelo.

Los instrumentos de evaluación son: las métricas de anclaje *pointing-game*, *energy-in-bbox* y *lift* (energía dentro de la caja dividida por su área, es decir, la mejora sobre el azar); las métricas de discriminación (área bajo la curva ROC, AUC) con *test de permutación* e intervalos de confianza por *bootstrap*; y el etiquetado del error, para el que se emplean tres fuentes de verdad independientes a fin de evitar la circularidad de un único juez: (a) el diagnóstico estructurado oficial (términos MeSH de Open-I; hallazgos presentes/ausentes anotados por radiólogo en PadChest-GR), objetivo y reproducible; y (b) el juez basado en un modelo de lenguaje (metodología tipo G-Eval), que compara la narrativa completa generada con la referencia y la clasifica

Tabla 4.1: Conjuntos de datos empleados y su función en el trabajo.

Conjunto	Contenido	Función	Verdad
Open-I	Informes + MeSH	Estudio principal (in-dist.)	MeSH + juez
NIH ChestX-ray8	Cajas (8 patologías)	Anclaje objetivo	Cajas
PadChest-GR	Presentes/ausentes + cajas	Réplica (dominio, OOD)	Radiólogo + juez

como correcta, alucinada u omitida según una rúbrica predefinida. La concordancia entre las tres fuentes (por ejemplo, AUC 0,87 con juez, 0,82 con MeSH oficial sobre Open-I) sustenta la fiabilidad del etiquetado. El juez se ejecuta con escritura incremental y de forma reproducible sobre cada informe.

4.4 El marco de explicabilidad

El marco de explicabilidad implementado evalúa dos ejes complementarios: *dónde* mira el modelo y si *de verdad* depende de ello. El mapa de calor se obtiene agregando la atención que los tokens del informe dirigen a los tokens visuales del codificador. Para los modelos de tipo LLaVa, los tokens visuales forman una rejilla de 37×37 (1369 parches); se promedia la atención sobre capas y cabezas, se restringe a los tokens visuales y se reordena en la rejilla, obteniendo un mapa espacial que se superpone a la imagen. Se descarta la contribución de los tokens "sumidero" (posiciones de atención residual sin significado espacial). Sobre este mapa se calculan las métricas de anclaje frente a las cajas reales de NIH: el *energy-in-bbox* (fracción de energía de atención dentro de la caja), el *lift* (dicha fracción normalizada por el área, es decir, la mejora sobre el azar) y el *pointing-game* (si el máximo del mapa cae dentro de la caja).

La fidelidad de la explicación se evalúa por perturbación: se ocluye la región de máxima atención y se mide la caída de la log-probabilidad del hallazgo (*occ_ drop*). Una explicación fiel debería producir una caída apreciable si la región atendida realmente sustenta la afirmación; su ausencia indicaría que la atención no es causalmente responsable de la salida. Como se detalla en el capítulo de resultados, esta y otras métricas de forma *no* logran predecir la fiabilidad, lo que motiva el giro hacia la incertidumbre de la decisión.

4.5 Arquitectura del generador propio

El generador propio es un modelo codificador–atención cruzada–decodificador para la generación de informes de tórax. El codificador visual es un *Vision Transformer* (ViT) preentrenado que produce, para cada imagen, un embedding global (CLS) y una rejilla de características por parche; en las variantes más avanzadas se sustituye por **RAD-DINO** (Pérez-García et al., 2024) congelado (518 px, rejilla de 37 × 37 parches, 768 dimensiones), aprovechando un codificador de dominio de mayor calidad. El decodificador es un modelo de lenguaje GPT-2 al que se inyecta atención cruzada hacia las características visuales en cada bloque. Un aspecto clave de diseño es que dicha atención cruzada se introduce mediante una compuerta inicializada a cero: al comienzo del entrenamiento la contribución visual es nula y el decodificador se comporta exactamente como el GPT-2 preentrenado, lo que *preserva* sus pesos y evita el colapso de la generación; la compuerta aprende progresivamente cuánta información visual incorporar.

El entrenamiento se organiza en dos etapas. En la Etapa 1 (alineamiento visual–textual) se entrena únicamente el codificador y unas cabezas de proyección con una pérdida contrastiva de tipo InfoNCE (CLIP): los embeddings de imágenes e informes emparejados deben acercarse frente a los no emparejados. En la Etapa 2 (ajuste generativo) se entrena el modelo completo con una pérdida de modelado de lenguaje (entropía cruzada sobre el siguiente token). Opcionalmente, mediante ajuste eficiente en parámetros (PEFT), se congela el GPT-2 base y se entrenan solo las capas de atención cruzada, reduciendo los parámetros entrenables de unos 200 a unos 5 millones y mitigando la ceguera a la imagen.

Ante la restricción de datos narrativos, el modelo incorpora destilación de conocimiento, que se estudia mediante una ablación progresiva (M0–M3): **M0**, línea base sin destilación; en el eje textual, se destila desde **CXR-BERT** (Boecking et al., 2022) (bien como torre de texto congelada que aporta un embedding clínico, bien como objetivo de destilación que el modelo *student* aprende a predecir); y en el eje visual (**M3**), se destila el embedding CLS del ViT hacia el de RAD-DINO. Esta ablación permite aislar la contribución de cada fuente de conocimiento externo a la calidad y al anclaje del modelo resultante. La Figura 4.1 esquematiza la arquitectura y sus dos etapas de entrenamiento.

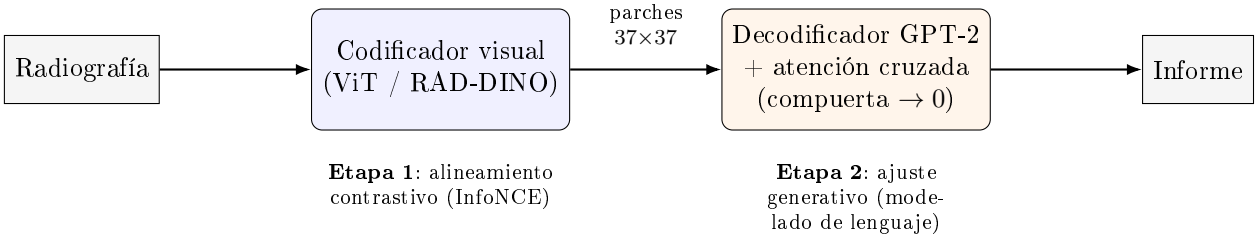


Figura 4.1: Arquitectura del generador propio: codificador visual, decodificador con atención cruzada mediante compuerta inicializada a cero, y las dos etapas de entrenamiento (alineamiento y generación).

4.6 Definición formal de las señales

Para garantizar la reproducibilidad, se definen formalmente las señales empleadas. Sea un informe generado la secuencia de tokens $(w_1, \ldots, w_n)$ con probabilidades $p_t = P(w_t \mid w_{<t}, \text{imagen})$ asignadas por el modelo en cada paso t.

Incertidumbre generativa. La señal principal es la probabilidad mínima de contenido, que excluye el token de apertura (cuya incertidumbre es de estilo y no de contenido):

$$u_{\text{mín}} = -\min_{2 \le t \le n} p_t. \tag{4.1}$$

Se calcula también la entropía predictiva por token, $H_t = -\sum_v p_t(v) \log p_t(v)$, de la que se toma el máximo $H_{\text{máx}} = \max_t H_t$. Para eliminar su confusión con la longitud, la entropía se residualiza respecto al número de tokens n mediante una regresión lineal $H_{\text{máx}} = \alpha + \beta n + \varepsilon$, tomando el residuo ε como señal limpia.

Auto-consistencia. Dadas K muestras $\{s_1, \ldots, s_K\}$ generadas por muestreo estocástico, se mide su acuerdo con la generación voraz g mediante la similitud de Jaccard de n-gramas de carácter:

$$\text{sim}(a, b) = \frac{|N(a) \cap N(b)|}{|N(a) \cup N(b)|}, \qquad c = \frac{1}{K} \sum_{k=1}^{K} \text{sim}(g, s_k), \tag{4.2}$$

donde $N(\cdot)$ es el conjunto de 4-gramas de carácter. Una baja consistencia c indica un contenido inestable entre muestras, señal candidata de alucinación.

Dependencia de la imagen. Se genera además un informe con la imagen en blanco $g_\varnothing$ y se calcula $\text{blank_sim} = \text{sim}(g, g_\varnothing)$: cuanto menor es, más depende de la imagen la salida real.

Anclaje objetivo. Sobre NIH, dado el mapa de calor normalizado h y la caja B de área relativa $|B|$, el lift mide la mejora sobre el azar de la energía de atención contenida en la caja:

$$\text{lift} = \frac{\sum_{(i,j)\in B} h_{ij}}{|B|}. \tag{4.3}$$

Un valor lift > 1 indica que la atención se concentra en la lesión por encima de lo esperable por azar.

4.7 Protocolo de etiquetado del error

La variable dependiente (*correcto*, *alucinación* u *omisión*) se determina por dos mecanismos complementarios. El etiquetado objetivo compara los hallazgos agudos afirmados por el modelo con la verdad estructurada (MeSH en Open-I; presentes/ausentes en PadChest-GR): se cuenta alucinación cuando el modelo afirma un hallazgo agudo ausente de la referencia, y omisión cuando omite uno presente. El etiquetado por juez (G-Eval) somete cada par (informe generado, referencia) a un modelo de lenguaje que aplica una rúbrica fija: se consideran significativos únicamente los hallazgos *agudos* (cardiomegalia, derrame, consolidación, edema, neumotórax, masa, nódulo, neumonía, infiltrado, atelectasia), ignorándose los crónicos, óseos, vasculares, técnicos o triviales; un informe es *correcto* si coincide con la referencia en los hallazgos significativos, *alucinación* si afirma uno ausente y *omisión* si pierde uno presente. La concordancia entre ambos mecanismos valida el etiquetado y mitiga la circularidad de depender de un único criterio.

4.8 Requisitos del sistema

Aunque el trabajo es fundamentalmente de investigación, el sistema resultante se especifica mediante requisitos, lo que ordena su diseño y su evaluación. Los requisitos funcionales (RF) son: **RF1**, generar el informe de una radiografía de tórax; **RF2**, extraer en inferencia las señales de incertidumbre sin generaciones adicionales obligatorias; **RF3**, calcular el anclaje de la explicación (mapa de calor o cajas); **RF4**, estimar y calibrar una confianza por informe; **RF5**, presentar informe, anclaje y confianza de forma integrada; y **RF6**, priorizar la revisión mediante bandas de riesgo. Los requisitos no funcionales (RNF) son: **RNF1**, ejecutarse en una única tarjeta de 12 GB mediante cuantización; **RNF2**, que la señal de confianza sea agnóstica al modelo y no incurra en coste de inferencia adicional; **RNF3**, reproducibilidad (extracción resumible, cálculo determinista); **RNF4**, interpretabilidad y honestidad

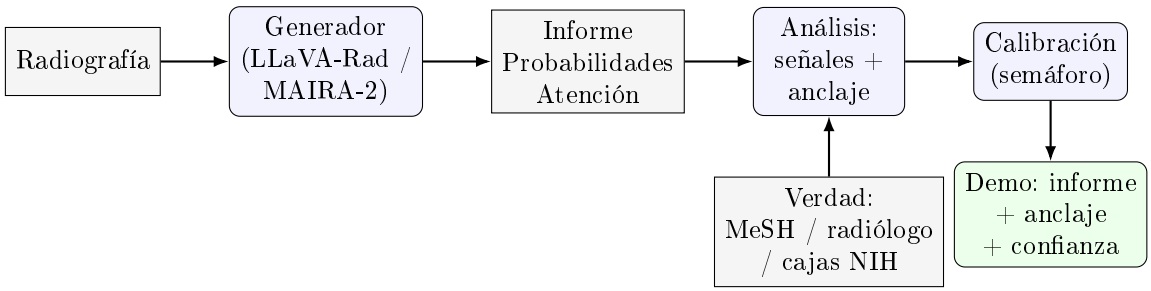


Figura 4.2: Flujo del sistema: de la radiografía al informe con anclaje y confianza calibrada. El bloque de análisis se valida contra la verdad objetiva (MeSH, hallazgos de radiólogo, cajas de NIH).

de la salida (comunicar las limitaciones); y **RNF5**, portabilidad y bajo coste de despliegue.

4.9 Arquitectura de la solución

La solución se organiza en cinco capas. La capa de datos gestiona los conjuntos (Open-I, NIH, PadChest-GR), su descarga, anonimización y preprocesado. La capa de modelo e inferencia carga los generadores cuantizados y produce, por imagen, el informe, las probabilidades y entropías por token, las muestras estocásticas y la atención visual. La capa de análisis y explicabilidad calcula a partir de lo anterior las señales de incertidumbre, las métricas de anclaje y las etiquetas de error. La capa de calibración transforma la señal en una probabilidad con bandas de riesgo (el semáforo). Y la capa de presentación materializa el sistema en la demostración interactiva. Esta separación por capas favorece la reutilización (el marco de análisis es *agnóstico al generador*) y facilita sustituir un modelo por otro sin alterar el resto. La Figura 4.2 representa el flujo completo del sistema.

4.10 Casos de uso

Se contemplan cuatro casos de uso principales. **CU-01 (radiólogo): obtener informe y confianza**: el usuario carga una radiografía y el sistema devuelve el informe, el anclaje y la banda de confianza. **CU-02 (radiólogo): consultar el anclaje**: inspeccionar dónde sustenta el modelo su afirmación, como apoyo a la lectura. **CU-03 (radiólogo): priorizar la revisión**: ordenar la carga de trabajo atendiendo primero a los informes en zona roja. Y **CU-04 (investigador): auditar y reproducir**: extraer las señales sobre un conjunto y reproducir las métricas de anclaje y

detección.

4.11 Planificación y desarrollo

El proyecto se ha desarrollado de forma incremental, con control de versiones (Git) y gestión de tareas por incrementos, organizándose en seis fases que se describen a continuación. Cada fase produce un artefacto verificable (un componente de software o un resultado experimental) antes de avanzar a la siguiente, lo que permite congelar resultados y retomar procesos largos entre sesiones. El trabajo de campo experimental (extracción de señales y etiquetado sobre miles de imágenes) se ejecuta en procesos reanudables que sobreviven a interrupciones, dado el tiempo de cómputo en hardware de consumo.

4.12 Diseño experimental

El trabajo se estructura en seis fases experimentales.

1. **Modelo propio (POC).** Un codificador visual (Vision Transformer) y un decodificador de lenguaje (GPT-2) al que se inyecta atención cruzada en cada bloque mediante una compuerta inicializada a cero, que preserva los pesos preentrenados. El entrenamiento sigue dos etapas: alineamiento contrastivo (InfoNCE) y ajuste generativo. Se realiza una ablación (M0–M3) que introduce progresivamente la destilación de conocimiento textual (CXR-BERT (Boecking et al., 2022)) y visual (RAD-DINO (Pérez-García et al., 2024)).

2. **Elevación a un modelo del estado del arte.** El marco de explicabilidad se aplica a LLaVA-Rad, ejecutado en el hardware local mediante cuantización a 8 bits, adaptando la extracción de mapas a su arquitectura de tokens visuales antepuestos.

3. **Anclaje objetivo.** Validación del anclaje contra las cajas de NIH.

4. **Detección de errores.** Estudio multi-señal de la fiabilidad, combinando morfología, incertidumbre, dependencia de imagen y consistencia, con etiqueta objetiva (MeSH) y juez.

5. **Réplica cruzada (diseño 2×2).** La señal se valida sobre un **segundo generador del estado del arte, MAIRA-2** (Bannur et al., 2024), y sobre un

segundo dominio, PadChest-GR, cruzando ambos factores (dos modelos × dos dominios). MAIRA-2 se ejecuta también cuantizado a 8 bits; al haber sido entrenado con PadChest, su evaluación *in-distribution* se realiza sobre PadChest y la evaluación *fuera de distribución* sobre Open-I, ajeno a su entrenamiento. Se aprovecha además su capacidad de anclaje explícito (cajas) para contrastar por tercera vía si la localización de la explicación predice la fiabilidad.

6. **Calibración y confianza operativa.** La señal final se calibra para expresar la fiabilidad como una probabilidad con bandas de riesgo ("semáforo"), y se materializa en una demostración interactiva que integra informe, anclaje y confianza.

4.13 Métricas de evaluación

La evaluación cuantitativa se apoya en un conjunto de métricas que conviene definir formalmente.

Discriminación (AUC–ROC). La capacidad de una señal para separar dos clases se mide con el área bajo la curva ROC. La curva ROC representa la sensibilidad (tasa de verdaderos positivos) frente a la tasa de falsos positivos al variar el umbral de decisión. El AUC admite una interpretación probabilística: es la probabilidad de que una instancia positiva reciba una puntuación mayor que una negativa elegida al azar, y equivale al estadístico de Mann–Whitney,

$$\mathrm{AUC} = \frac{1}{n_+ n_-} \sum_{i \in \mathcal{P}} \sum_{j \in \mathcal{N}} \mathbf{1}[s_i > s_j], \tag{4.4}$$

donde $\mathcal{P}$ y $\mathcal{N}$ son los conjuntos de positivos y negativos y s las puntuaciones. Un valor de 0,5 indica ausencia de discriminación y 1,0 discriminación perfecta. Se calcula mediante rangos para garantizar reproducibilidad.

Significancia (test de permutación). Para contrastar si un AUC observado supera al azar (especialmente con clases desbalanceadas) se emplea un test de permutación: se permutan aleatoriamente las etiquetas un número elevado de veces, se recalcula el AUC en cada permutación y se obtiene el p-valor como la fracción de valores nulos que igualan o superan al observado.

Intervalos de confianza (*bootstrap*). La incertidumbre de la estimación se cuantifica por *bootstrap* estratificado: se remuestrean con reemplazo, por separado, los positivos y los negativos un número elevado de veces (2000 en este trabajo), y el intervalo de confianza al 95 % se toma de los percentiles 2,5 y 97,5 de la distribución de AUC remuestreados.

Calibración. Que una señal discrimine no implica que esté calibrada. La calibración se evalúa con la curva de fiabilidad, que compara la probabilidad predicha con la tasa de acierto observada por grupos, y con el *Brier score*, el error cuadrático medio entre la probabilidad predicha $\hat{p}_i$ y el resultado y_i: Brier $= \frac{1}{n}\sum_i(\hat{p}_i - y_i)^2$. Sobre esta base se definen las bandas de riesgo del semáforo.

Anclaje y similitud. El anclaje se mide con el *lift*, el *energy-in-bbox* y el *pointing-game* ya definidos; la consistencia textual, con la similitud de Jaccard de n-gramas de carácter.

4.14 Método científico y control de confusores

El trabajo sigue un enfoque hipotético-deductivo: se formulan hipótesis falsables (H1–H4, Sección 4.2) y se diseñan experimentos que puedan refutarlas. Tres principios metodológicos guían la investigación. Primero, la validación contra verdad objetiva: siempre que es posible, las señales se contrastan con referencias externas (cajas reales, diagnóstico estructurado) en lugar de con otras señales del propio modelo, y el etiquetado del error se triangula con tres fuentes independientes. Segundo, el control de confusores: se identifican y neutralizan las variables espurias que podrían simular una señal: la longitud del informe (por residualización), la posición del token (usando la probabilidad de contenido) o el tipo de mapa de calor (mediante comparaciones emparejadas). Tercero, la replicación: los hallazgos se comprueban en un diseño cruzado de dos modelos por dos dominios antes de darlos por robustos. Este rigor resultó decisivo: varias señales de apariencia prometedora (el máximo de atención, la entropía cruda, la relación *lift*–acierto) se revelaron artefactos que solo un control cuidadoso de confusores permitió descartar, subrayando la importancia del método sobre el resultado aparente.

4.15 Modelo de análisis de datos

El análisis es fundamentalmente cuantitativo. La capacidad discriminativa de cada señal se mide mediante AUC univariante; las señales se combinan con regresión logística evaluada por validación cruzada out-of-fold (de modo que cada predicción se obtiene sobre datos no empleados en el ajuste) y su significancia se contrasta con tests de permutación que controlan el desbalance de clases. Se prestó especial atención al control de *confounds* (régimen de la muestra, longitud del informe y artefactos del máximo de atención), validando cada señal frente a una referencia continua u objetiva para descartar espejismos. La exploración de señales adicionales se realiza sobre los tres conjuntos a la vez, exigiendo que cualquier mejora *generalice*; se comprueba que ninguna combinación multi-señal supera de forma consistente a la probabilidad mínima de contenido por sí sola (las demás señales resultan específicas de modelo o de dominio), por lo que la fórmula final privilegia la simplicidad robusta de una única señal frente a un combinado sobreajustado. Esta se calibra para expresar la fiabilidad como una probabilidad con su intervalo de confianza (*bootstrap*) y bandas de riesgo. El software empleado es Python (PyTorch, `transformers`, NumPy) y la cuantización se realiza con `bitsandbytes`; el AUC y los intervalos se calculan con estimadores basados en rangos para garantizar reproducibilidad.

Capítulo 5

Presentación de análisis, resultados y discusión

En este capítulo se describe la muestra analizada, se presentan los resultados y se discute su significado. La línea argumental es la siguiente: la atención del modelo está clínicamente anclada, pero su morfología no permite estimar la fiabilidad; esta reside en la *incertidumbre de la decisión* del propio modelo y se detecta, sobre todo, para un tipo de error (las alucinaciones). Se demuestra que la señal es *agnóstica al modelo* y *robusta al dominio* validándola sobre dos generadores (LLaVA-Rad y MAIRA-2) y dos dominios (Estados Unidos y España), y se traduce en una confianza calibrada apta para el cribado clínico.

5.1 Análisis descriptivo de la muestra

El estudio de fiabilidad se articula como un diseño 2×2 que cruza dos generadores, LLaVA-Rad (7B, entrenado sobre MIMIC-CXR) y MAIRA-2 (7B, entrenado sobre MIMIC-CXR, PadChest y USMix), con dos dominios: Open-I (Indiana University, EE. UU.) y PadChest-GR (España). Para cada celda se generan informes y se etiqueta cada uno como *correcto*, *alucinación* (afirmar un hallazgo agudo ausente) u *omisión* o *miss* (perder un hallazgo agudo presente). El etiquetado combina tres fuentes de verdad independientes para evitar la circularidad de un único juez: diagnóstico estructurado oficial (MeSH de Open-I; hallazgos presentes/ausentes de PadChest-GR) y juicio basado en modelo de lenguaje sobre la narrativa completa (*G-Eval*). El anclaje de la atención se evalúa aparte sobre las 984 anotaciones con caja de NIH ChestX-ray8. La Tabla 5.1 resume las cuatro celdas. La prevalencia de error y el predominio de informes normales son característicos del dominio; la

Tabla 5.1: Muestra del diseño 2×2 (etiquetas objetivas/G-Eval). n = informes; alu = alucinaciones; mis = omisiones.

Generador	Dominio	n	alu	mis
LLaVA-Rad	Open-I (in-distribution)	800	110	228
LLaVA-Rad	PadChest (OOD)	381	33	130
MAIRA-2	PadChest (in-distribution)	379	27	80
MAIRA-2	Open-I (OOD)	300	12	22

cardiomegalia sobre-diagnosticada en tórax normal aparece como sesgo sistemático de *ambos* generadores.

5.2 El generador propio y la lección sobre las métricas

El generador propio se desarrolló de forma deliberada como paso previo a emplear un modelo del estado del arte ya entrenado: construirlo desde cero permite observar su funcionamiento interno (cómo se integra la señal visual en la generación de texto, y dónde falla) de un modo que un modelo de caja cerrada no ofrece, y expone de primera mano las limitaciones propias de un modelo de menor capacidad entrenado con datos escasos. En su implementación se documentaron y resolvieron dos fallos característicos. El primero, el colapso de la generación al inyectar la atención cruzada: la contribución visual, inicialmente ruidosa, desestabilizaba el decodificador preentrenado; se mitigó con la compuerta inicializada a cero, que preserva el comportamiento del modelo de lenguaje y deja que la señal visual se incorpore de forma gradual. El segundo, la ceguera a la imagen: el decodificador tendía a ignorar la imagen y a reproducir la plantilla mayoritaria; se mitigó congelando el decodificador base y entrenando solo la atención cruzada (PEFT).

Sobre esta base se diseñó una ablación (Tabla 5.2) que introduce progresivamente la destilación de conocimiento textual y visual, con el objetivo de medir su efecto sobre la calidad y el anclaje. La lección metodológica más relevante emergió al evaluar estas variantes: la métrica ROUGE engaña. Una variante mejor anclada a la imagen, que describe hallazgos reales, puede obtener un ROUGE *inferior* al de un modelo ciego que memoriza la plantilla "normal", porque en un dominio dominado por informes normales el solapamiento léxico premia la reproducción de la plantilla, no la lectura de la imagen. Este hallazgo, coherente con la crítica del Capítulo 3, motivó el abandono de las métricas de solapamiento en favor de la corrección clínica y, en última instancia, el giro de todo el trabajo hacia la fiabilidad. Junto con las

Tabla 5.2: Ablación de destilación del generador propio (M0–M3): fuentes de conocimiento introducidas.

Variante	Destilación textual	Destilación visual
M0 (línea base)	—	—
M1	CXR-BERT (torre congelada)	—
M2	CXR-BERT (destilación al *student*)	—
M3	CXR-BERT (destilación)	RAD-DINO (CLS → CLS)

Tabla 5.3: Anclaje objetivo sobre NIH (n = 388 hallazgos detectados). Lift = energía-en-caja / azar.

Patología	Detección	Lift	Pointing
Nódulo	0,22	7,91	0,47
Masa	0,18	5,10	0,87
Atelectasia	0,29	3,45	0,30
Derrame	0,58	3,23	0,36
Neumotórax	0,74	2,81	0,37
Neumonía	0,29	2,67	0,23
Infiltrado	0,19	2,62	0,48
Cardiomegalia	0,58	1,63	0,39
Global	0,39	**3,03**	0,38

limitaciones de capacidad ya observadas en el propio modelo, esta lección sobre las métricas es la que llevó a elevar el análisis a un MLLM del estado del arte (LLaVA-Rad): solo un generador de calidad suficiente permite separar los errores reales de los artefactos de un modelo de escala reducida, y solo evaluando la corrección clínica (no el solapamiento léxico) tiene sentido preguntarse si la explicación o la incertidumbre predicen la fiabilidad.

5.3 La atención está clínicamente anclada

Contrastada con las cajas reales de NIH, la atención de LLaVA-Rad se concentra sobre la lesión muy por encima del azar: lift global 3,03 y *pointing-game* 0,38 (3,7 veces el azar). El anclaje varía con sentido clínico (Tabla 5.3): fuerte en hallazgos focales pequeños (nódulo, masa), débil en la cardiomegalia, difusa y de caja grande. Este resultado justifica el uso del mapa de calor como puntero de *dónde* mira el modelo, pero, como se verá, no como medida de *cuánto* fiarse.

La Figura 5.1 ilustra visualmente este anclaje: para cada patología se muestran los casos de mayor *lift*, con el mapa de calor superpuesto y la caja real. Se observa que la

atención se concentra sobre la lesión, de forma especialmente nítida en los hallazgos focales pequeños (nódulo, masa, neumotórax) y más difusa en la cardiomegalia, de caja grande.

A modo de contraste, la Figura 5.2 muestra los casos de *lift* mediano por patología: el anclaje sigue siendo apreciable pero más difuso, ilustrando que la calidad de la localización varía de forma continua y que no todos los aciertos van acompañados de una atención igualmente concentrada.

5.4 La morfología de la explicación no predice la fiabilidad

Ninguna característica geométrica del mapa de calor (concentración, dispersión, agrupamiento) separa de forma robusta los informes correctos de los erróneos (AUC 0,54; no significativo). Las señales que aparentaban serlo resultaron artefactos detectados al validarlas: la aparente relación entre anclaje (*lift*) y acierto desaparece (AUC 0,52) al emplear un mapa de calor homogéneo, revelándose como un artefacto de contrastar mapas por-hallazgo con mapas globales. El resultado se confirma por tercera vía con las cajas de anclaje propias de MAIRA-2: el modelo localiza sus hallazgos *inventados* con cajas anatómicamente plausibles (una caja sobre el corazón para una cardiomegalia inexistente, sobre el pulmón para una enfermedad intersticial inexistente), de modo que la presencia y la forma del anclaje acompañan a la *afirmación*, no al *acierto* (frecuencia de caja del 19 % en alucinaciones frente al 7 % en informes correctos, dirección inútil como señal). En resumen, ni el mapa de calor de atención, ni el *lift* sobre NIH, ni las cajas entrenadas del propio modelo permiten leer la fiabilidad en la morfología de la explicación.

5.5 La incertidumbre de la decisión detecta las alucinaciones

Frente a la morfología, la incertidumbre generativa (operacionalizada como la probabilidad mínima de *contenido* de los tokens del informe) sí discrimina la alucinación del acierto. La Figura 5.3 muestra, para las cuatro celdas, las distribuciones de esta señal en informes correctos, con omisión y con alucinación. *Se incluye esta figura porque hace visible el resultado central*: las alucinaciones (rojo) se desplazan hacia la baja confianza y se separan de los informes correctos (verde), con la única excepción

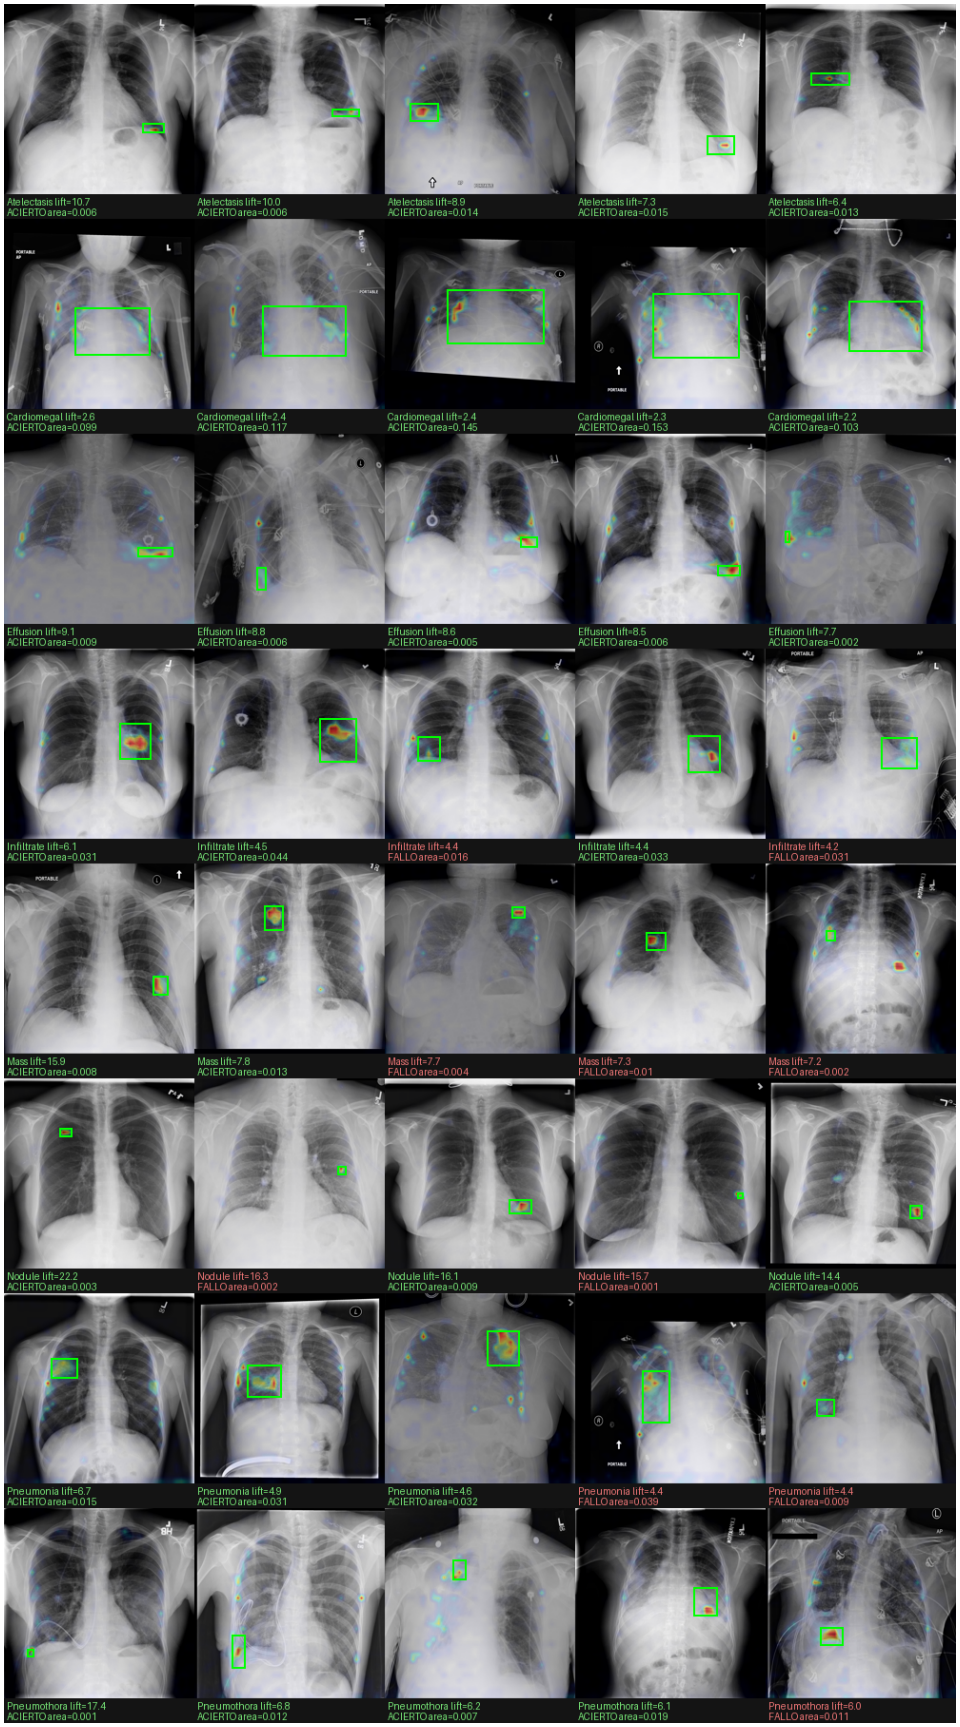


Figura 5.1: Anclaje de la atención sobre NIH por patología (casos de mayor *lift*). Mapa de calor superpuesto y caja real (verde); se indica el *lift*, el acierto/fallo del veredicto y el área relativa de la caja. La atención se concentra sobre la lesión, sobre todo en hallazgos focales.

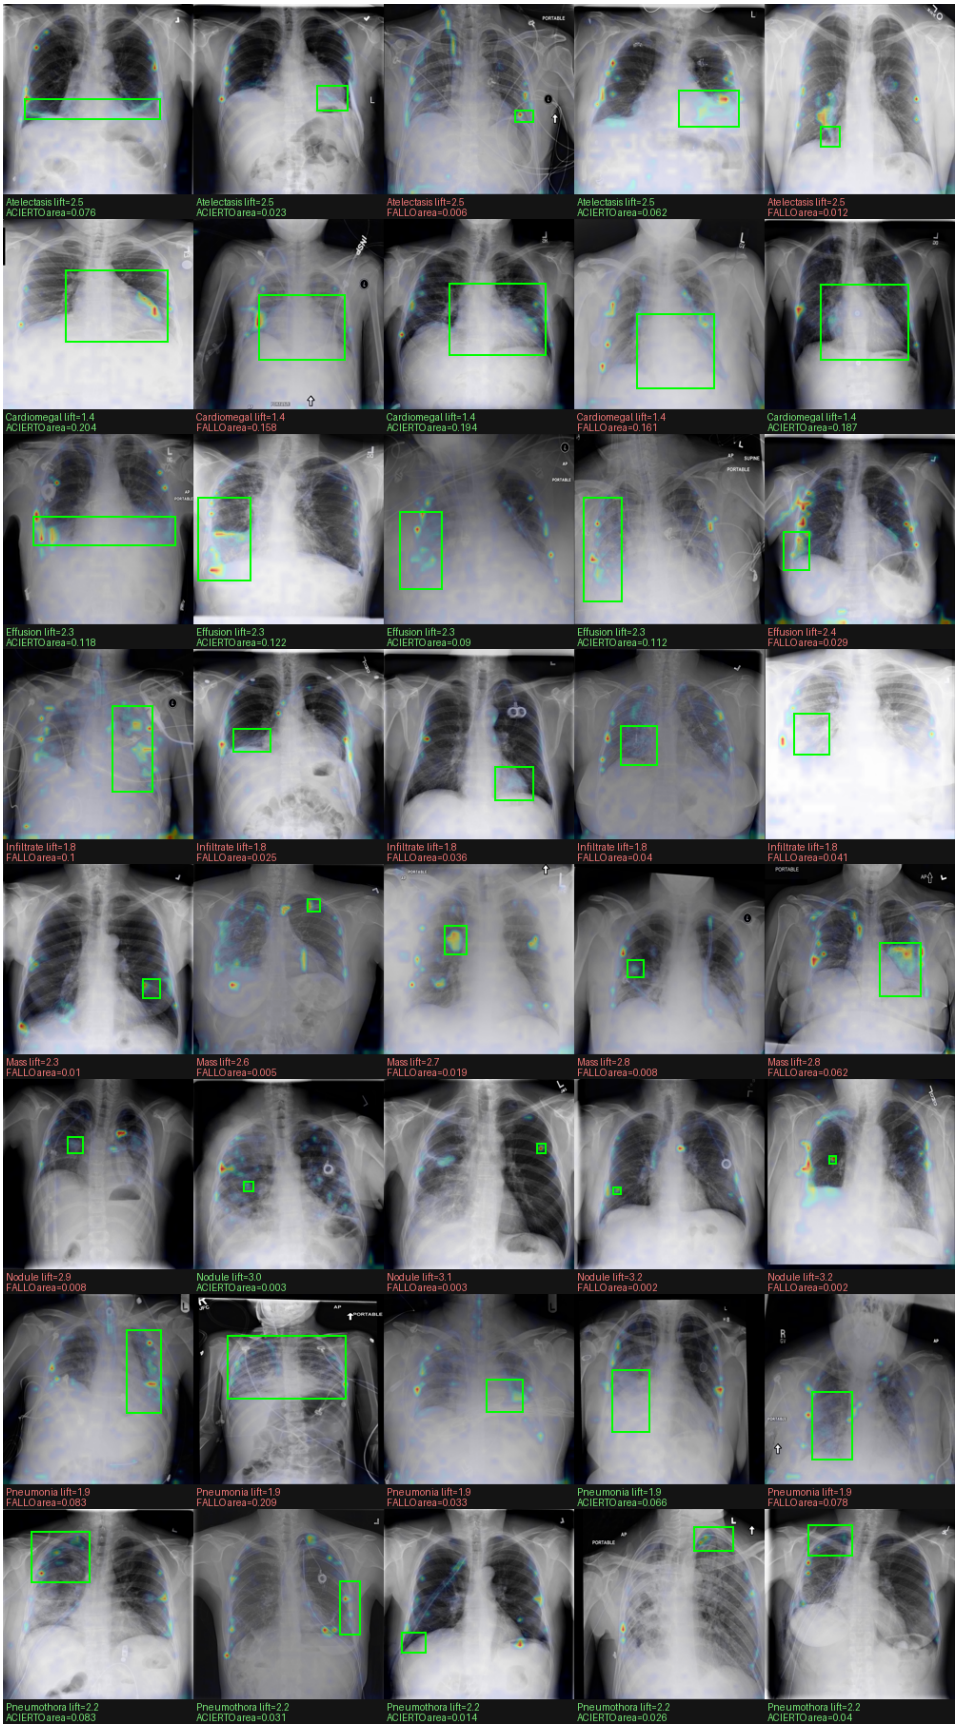


Figura 5.2: Anclaje sobre NIH por patología en casos de *lift* mediano. La atención sigue sobre la región de la lesión pero de forma más difusa que en los casos de la Figura 5.1.

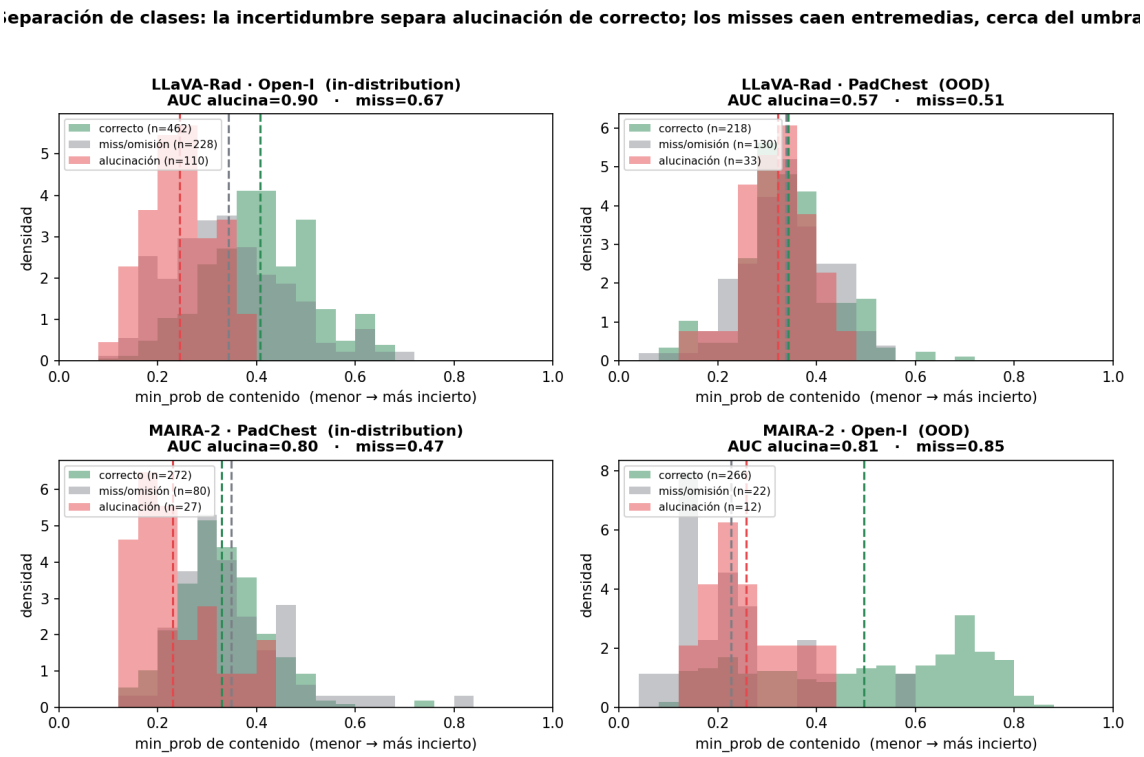


Figura 5.3: Separación de clases de la probabilidad mínima de contenido (menor = más incierto) en las cuatro celdas del diseño. Verde: correcto; gris: omisión; rojo: alucinación; líneas discontinuas: medias. Las alucinaciones se concentran en la zona incierta salvo en LLaVA-Rad·PadChest (OOD).

de LLaVA-Rad fuera de distribución, donde ambas distribuciones se solapan.

El token de apertura contamina la señal (aportación metodológica). La probabilidad mínima calculada sobre *todo* el informe rinde de forma mediocre porque el mínimo recae casi siempre en el token de *apertura* del informe ("The", "Frontal"...), que refleja incertidumbre de estilo, no de contenido, y es uniformemente baja en todos los casos. Excluir ese primer token (usar la probabilidad mínima de contenido) eleva sustancialmente la detección en las cuatro celdas (Figura 5.4). *Se justifica esta figura porque aísla una decisión de diseño con impacto grande y generalizable*: el AUC pasa de 0,71 a 0,90 en Open-I y de 0,50 a 0,80 en MAIRA-2·PadChest, sin coste alguno. La interpretación de este efecto es instructiva: el primer token del informe concentra la incertidumbre *estilística*, qué fórmula de apertura emplear ("The", "Frontal"...), que es alta y uniforme en todos los informes con independencia de su contenido, y que por tanto *no discrimina* y solo añade ruido al mínimo. Al restringir la señal al contenido, esta pasa a reflejar la incertidumbre *diagnóstica* del modelo. Más allá de la mejora numérica, el hallazgo ilustra un principio general aplicable a otras tareas de generación: al resumir la incertidumbre de una secuencia

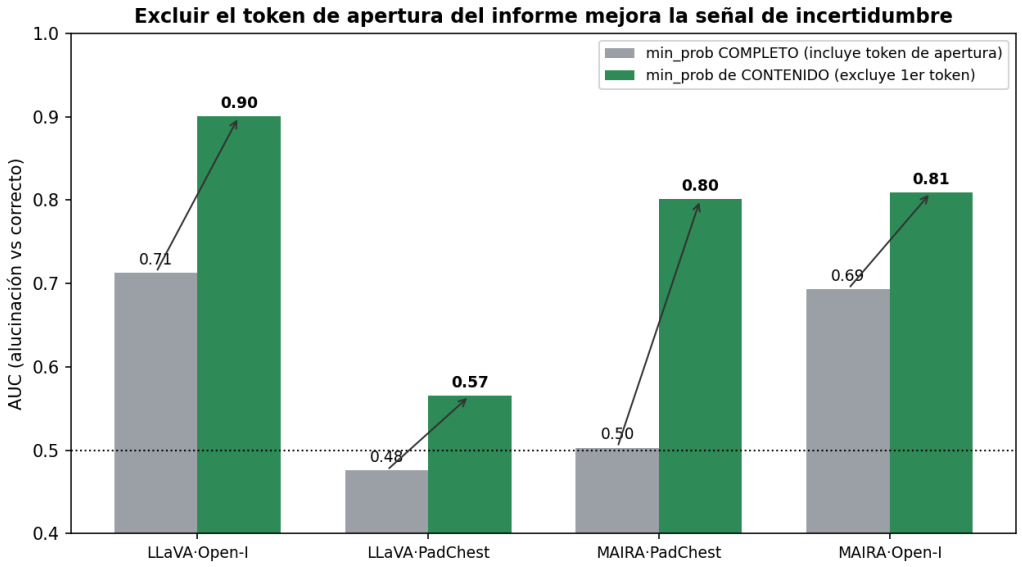


Figura 5.4: Efecto de excluir el token de apertura. Barras grises: probabilidad mínima sobre todo el informe; barras verdes: sobre el contenido (sin el primer token). La mejora es sistemática en las cuatro celdas.

conviene separar la duda sobre la forma de la duda sobre el fondo, pues solo la segunda informa sobre la fiabilidad del contenido.

La señal es agnóstica al modelo y robusta al dominio. La Figura 5.5 sintetiza el resultado principal como matriz 2×2. *Se incluye porque resume, en una sola imagen, la validez externa del método*: la detección es fuerte in-distribution (LLaVA-Rad 0,90; MAIRA-2 0,80) y, crucialmente, se mantiene fuera de distribución para el modelo de mayor calidad (MAIRA-2 0,81, prácticamente igual que su valor in-distribution). La única celda débil es LLaVA-Rad fuera de distribución (0,61): un generador limitado, al enfrentarse a imágenes ajenas a su entrenamiento, recae en un informe-plantilla emitido con confianza, lo que erosiona la señal. La degradación fuera de distribución es, por tanto, una limitación del generador débil, no del método. Este matiz es importante porque invierte la conclusión que se habría extraído de haber estudiado un único generador: con LLaVA-Rad aislado, la caída a 0,61 fuera de distribución sugeriría que la fiabilidad por incertidumbre no generaliza; el diseño cruzado revela que sí lo hace cuando el modelo es lo bastante bueno, y que el problema reside en que un generador débil, ante imágenes ajenas a su entrenamiento, deja de leer la imagen y "rellena" con su plantilla más probable, emitida con confianza. La lección práctica es doble: conviene, primero, elegir un generador de calidad, y segundo, calibrar y verificar la señal en cada dominio de despliegue antes de confiar en ella.

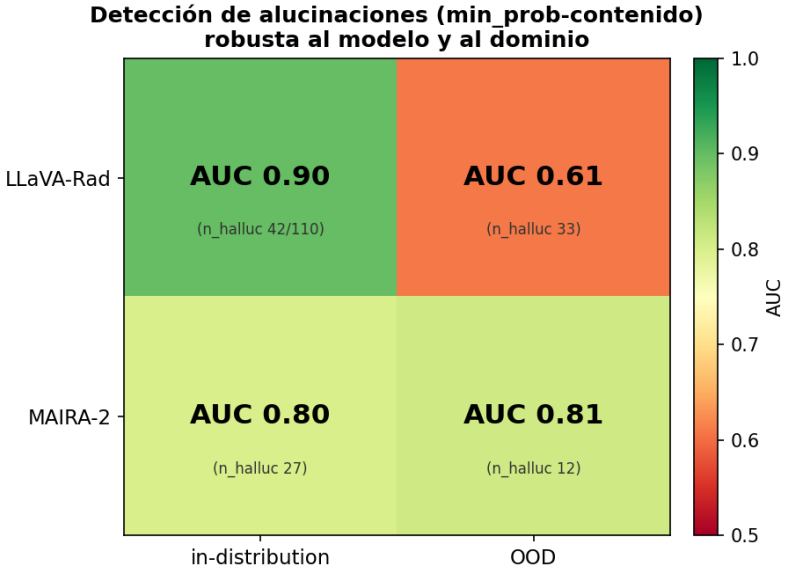


Figura 5.5: AUC de detección de alucinaciones (probabilidad mínima de contenido) en el diseño 2×2. Verde = alto. La señal es robusta salvo en el generador débil fuera de distribución.

Las curvas ROC de la Figura 5.6 caracterizan el compromiso sensibilidad–especificidad de la señal en las cuatro celdas. *Se muestran porque traducen el AUC agregado en el comportamiento operativo*: las tres celdas robustas dominan claramente la diagonal de azar, mientras que LLaVA-Rad·PadChest se aproxima a ella, coherente con el solapamiento de la Figura 5.3.

5.5.1 Ninguna señal adicional generaliza: en favor de la simplicidad

Se exploró si combinar la probabilidad mínima de contenido con otras señales agnósticas (entropía, verosimilitud media, auto-consistencia, dependencia de imagen) mejoraba la detección. La exploración se realizó exigiendo que cualquier mejora *generalizara* sobre los tres conjuntos con suficiente número de alucinaciones. La Tabla 5.4 muestra el AUC univariante de cada señal por conjunto: ninguna supera de forma consistente a la probabilidad mínima de contenido. Señales fuertes en los conjuntos de LLaVA-Rad (entropía, verosimilitud) resultan inútiles en MAIRA-2, y la dependencia de imagen ayuda en MAIRA-2 pero se invierte en Open-I; son, por tanto, específicas de modelo o de dominio. En consecuencia, la fórmula final privilegia la simplicidad robusta de una única señal frente a un combinado sobreajustado que no transferiría.

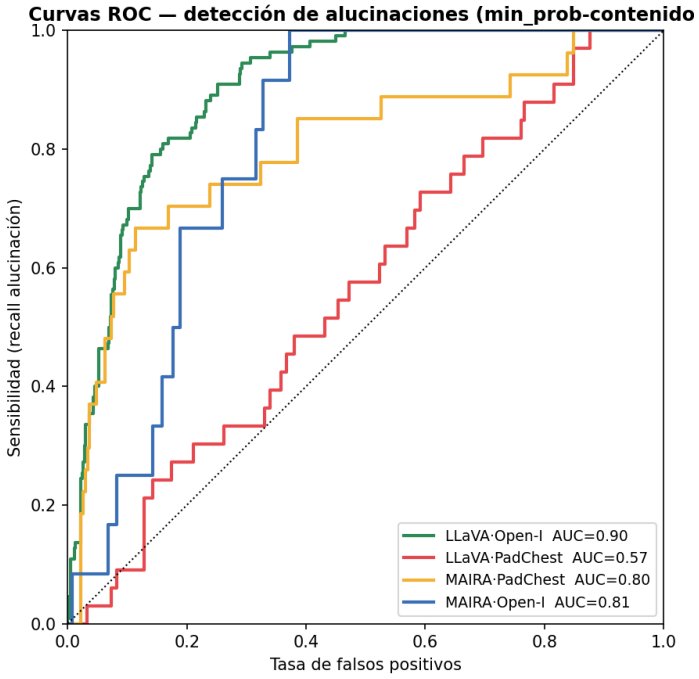


Figura 5.6: Curvas ROC de detección de alucinaciones (probabilidad mínima de contenido). Tres de las cuatro celdas dominan la diagonal de azar; LLaVA-Rad·PadChest (OOD) se aproxima a ella.

5.6 Disociación alucinación–omisión

La detección es *asimétrica*. La Figura 5.7 contrasta, por celda, el AUC para separar alucinaciones frente a correctos y omisiones frente a correctos. *Se justifica esta figura porque delimita con honestidad el alcance del método*: la señal detecta las alucinaciones de forma robusta (0,80–0,90), pero las omisiones solo de forma parcial y variable (0,47–0,85). Las omisiones no son siempre errores "confiados"; como se aprecia en la Figura 5.3 (distribución gris), tienden a situarse *entre* los correctos y las alucinaciones, cerca del umbral, y fuera de distribución (MAIRA-2·Open-I) se desplazan hacia la incertidumbre. La interpretación es que, cuando el modelo fabrica un hallazgo, titubea; cuando lo omite emitiendo un informe normal, a menudo lo hace con confianza próxima a la de un informe normal correcto, aunque no siempre. En consecuencia, la fórmula es un *detector de alucinaciones* que captura además una fracción de omisiones como beneficio colateral, no un detector general de error.

Tabla 5.4: AUC univariante de cada señal (orientada: mayor = más probable alucinación) por conjunto. Ninguna mejora de forma consistente a la probabilidad mínima de contenido.

Señal	Open-I (LLaVA)	PadChest (LLaVA)	PadChest (MAIRA)
min_prob de contenido	**0,90**	**0,57**	**0,80**
Percentil 5 de probabilidad	0,90	0,61	0,58
Verosimilitud media	0,89	0,65	0,49
Entropía media	0,92	0,65	0,46
Auto-consistencia	0,73	0,43	0,65
Dependencia de imagen (blank)	0,32	0,51	0,70

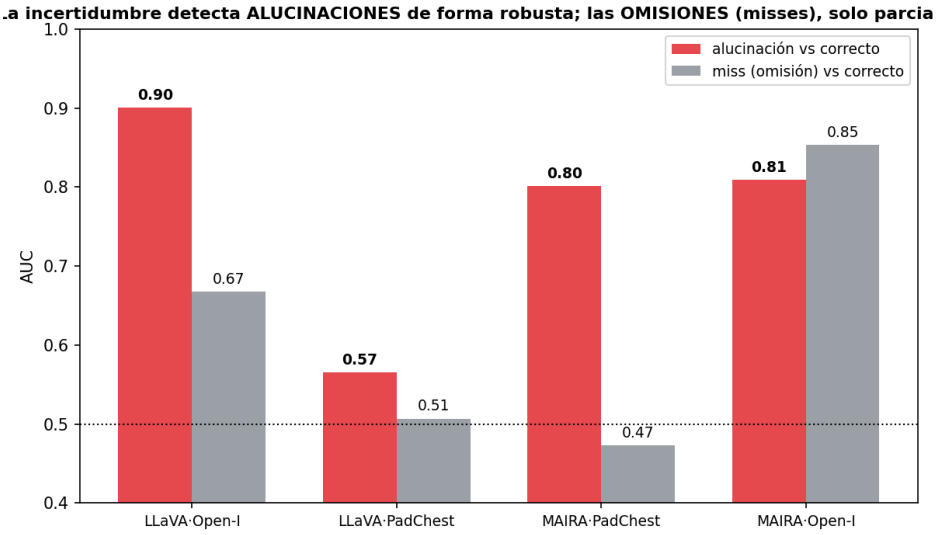


Figura 5.7: Disociación: AUC para separar alucinaciones (rojo) y omisiones (gris) de los informes correctos, por celda. La incertidumbre detecta alucinaciones de forma robusta y omisiones solo parcialmente.

5.7 Calibración y confianza operativa

Para convertir la señal en una salida clínica se estudia su calibración. La Figura 5.8 representa la tasa de alucinación observada en función de la probabilidad mínima de contenido: *se incluye porque es el fundamento empírico del "semáforo" de confianza*, al mostrar una relación monótona (a menor confianza del modelo, mayor tasa de alucinación observada) sobre la que se definen bandas de riesgo. Sobre Open-I, las bandas por cuartiles del grupo correcto arrojan una tasa de alucinación del 30 % en la banda roja (revisar), 6 % en la amarilla y ≈0 % en las verdes. Como priorizador de revisión (Tabla 5.5), un umbral de Youden captura el 84 % de las alucinaciones (y, además, el 44 % de las omisiones, como beneficio colateral) revisando en torno a un tercio de los estudios; a especificidad del 95 %, el 53 % de las alucinaciones revisando solo el 5 %. La propuesta no es, pues, un clasificador binario (la baja

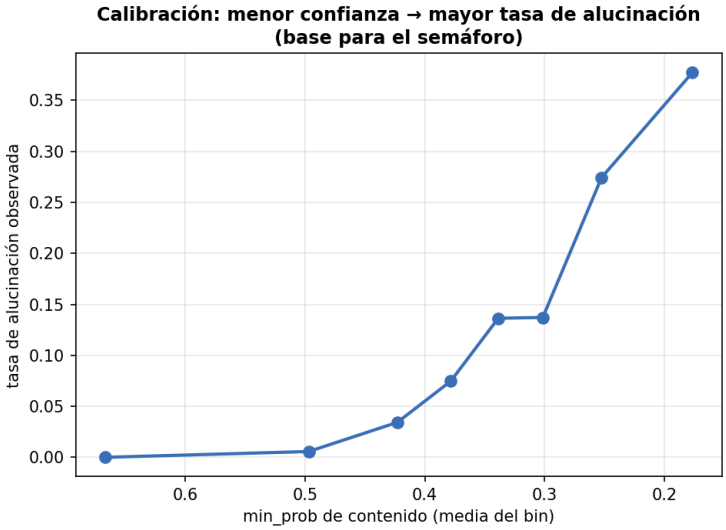


Figura 5.8: Calibración: tasa de alucinación observada frente a la probabilidad mínima de contenido (media por decil, datos agregados). La relación monótona fundamenta las bandas del semáforo de confianza.

Tabla 5.5: Puntos de operación sobre Open-I (verdad MeSH; puntuación de contenido). FA = falsas alarmas.

Umbral	Recall alucinación	Recall omisión	FA
Youden	84 %	44 %	15 %
Especificidad 90 %	71 %	33 %	10 %
Especificidad 95 %	53 %	20 %	5 %

prevalencia lo haría poco preciso) sino una confianza calibrada con intervalo que ordena la carga de revisión, con el radiólogo como decisor.

5.8 Traducción clínica: la confianza como semáforo

Los resultados anteriores solo tienen valor si pueden *presentarse* al clínico de una forma que mejore su trabajo sin introducir nuevos riesgos. Esta sección justifica las decisiones de diseño de la demostración desarrollada y su encaje en un entorno médico real.

5.8.1 Por qué una demostración interactiva

Se ha optado por materializar el sistema en una demostración interactiva (con la biblioteca Gradio) que, ante una radiografía, muestra en un único panel tres elementos: el informe generado, el anclaje (dónde mira el modelo, mediante mapa de calor o

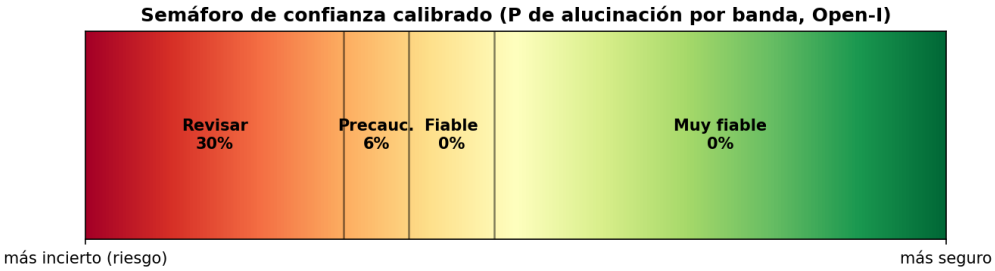


Figura 5.9: Semáforo de confianza en gradiente. Las bandas, definidas sobre los cuartiles de la distribución de los informes correctos, se anotan con la probabilidad de alucinación observada. El verde concentra los informes fiables (baja fricción) y el rojo prioriza la revisión.

cajas) y la confianza calibrada (cuánto fiarse). La elección responde a tres criterios. Primero, la reproducibilidad y accesibilidad: una interfaz web ligera permite que un radiólogo, un investigador o un evaluador reproduzcan el comportamiento del sistema sin conocimientos técnicos ni instalación compleja. Segundo, la integración de las tres señales en una sola vista, que es precisamente la propuesta del trabajo: informe, evidencia visual y fiabilidad no deben consultarse por separado. Y tercero, su idoneidad como prototipo para un estudio de lectura futuro, al permitir presentar casos controlados y recoger la interacción del clínico.

5.8.2 Un gradiente de confianza, no una alerta de error

La decisión de diseño más relevante es presentar la fiabilidad como un semáforo en gradiente (una banda continua de verde a rojo) en lugar de una alerta binaria de posible error. La justificación es doble. Por un lado, un clasificador binario sería *poco preciso* dada la baja prevalencia de las alucinaciones: generaría muchas falsas alarmas por cada acierto (véase Tabla 5.5). Por otro, y más importante, la literatura de sistemas de ayuda a la decisión clínica documenta el fenómeno de la fatiga de alarmas: cuando un sistema emite alertas frecuentes (muchas de ellas irrelevantes) los profesionales se *desensibilizan* y terminan ignorándolas, anulando su utilidad e incluso introduciendo riesgo. Un gradiente calibrado evita este efecto: la mayoría de los informes fiables permanecen en verde, de baja fricción, y la atención del radiólogo se prioriza hacia la minoría de casos de riesgo elevado, en lugar de dispersarse en una sucesión de alertas. La confianza se convierte así en un *ordenador de la carga de revisión*, coherente con los puntos de operación de la Tabla 5.5. La Figura 5.9 representa el semáforo con las bandas calibradas sobre Open-I.

La Figura 5.10 ilustra la salida de la demostración sobre dos ejemplos reales de MAIRA-2: un informe con una alucinación (una fabricación de infiltrado) que el

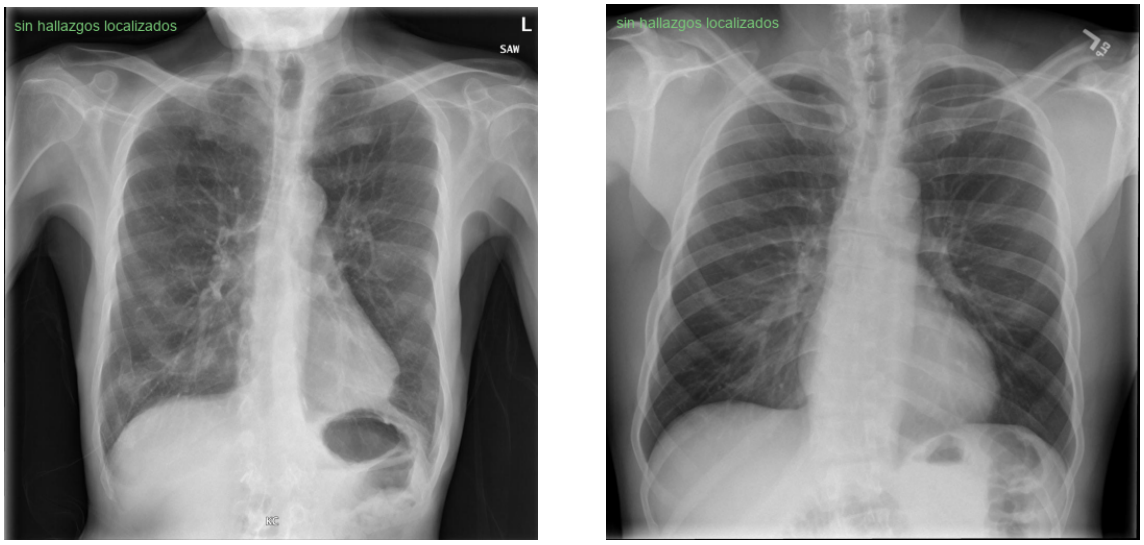


Figura 5.10: Salida de la demostración (MAIRA-2) con el anclaje por cajas. Izquierda: informe con una alucinación de infiltrado, con baja confianza (zona roja). Derecha: informe normal correcto, con alta confianza (zona verde).

sistema sitúa en zona roja (baja confianza), y un informe normal correcto que sitúa en zona verde.

5.8.3 El radiólogo como decisor y la mitigación del sesgo de automatización

El sistema se concibe explícitamente como asistivo, no autónomo: no emite un diagnóstico final ni bloquea informes, sino que aporta evidencia (anclaje) y una estimación de fiabilidad para que el radiólogo decida. Este diseño mitiga el sesgo de automatización (la tendencia a aceptar acríticamente la salida de un sistema automático) de dos formas. Primera, el anclaje se presenta como puntero de *dónde* mirar, no como prueba de acierto, evitando que una explicación plausible induzca confianza injustificada. Segunda, la leyenda del semáforo incorpora una advertencia honesta: el color mide la duda del modelo, de modo que el verde indica baja probabilidad de *alucinación* pero *no* garantiza la ausencia de *omisiones*, que el modelo comete con confianza. Comunicar esta limitación en la propia interfaz es una salvaguarda de seguridad, no un detalle menor. Finalmente, la calibración es específica de cada modelo (cada generador dispone de su propia calibración del semáforo), lo que reconoce que la relación entre confianza y acierto no es universal y debe establecerse por sistema antes de su despliegue.

5.9 Consideraciones éticas, legales y de sostenibilidad

El despliegue de un sistema como el propuesto en un entorno sanitario real está sujeto a un marco ético y normativo exigente que conviene explicitar. Desde el punto de vista legal y regulatorio, un sistema que asiste al diagnóstico se considera *producto sanitario* y queda sujeto a la regulación europea correspondiente (Reglamento de Productos Sanitarios) y, de forma creciente, al Reglamento de Inteligencia Artificial de la Unión Europea, que clasifica los sistemas de apoyo a la decisión clínica como de alto riesgo y les impone requisitos de transparencia, supervisión humana, gestión de riesgos y trazabilidad. El diseño asistivo del presente trabajo (con el radiólogo como decisor y una salida de confianza explicable y calibrada) se alinea con estos principios, especialmente con el de supervisión humana significativa. En cuanto a la protección de datos, el trabajo emplea exclusivamente conjuntos de acceso libre y anonimizados, evitando el tratamiento de datos personales; un despliegue clínico requeriría, además, las garantías del Reglamento General de Protección de Datos.

Desde el punto de vista ético, dos riesgos merecen atención. El primero es el sesgo: un modelo entrenado sobre poblaciones concretas puede rendir de forma desigual en otras, lo que este trabajo aborda parcialmente al evaluar la generalización a un dominio distinto y al recomendar una calibración específica por sistema y población antes del despliegue. El segundo es el ya mencionado sesgo de automatización, cuya mitigación se integra en el propio diseño de la interfaz. En cuanto a la sostenibilidad, el enfoque prioriza la eficiencia: todos los modelos se ejecutan cuantizados en una única tarjeta gráfica de consumo, y la señal de fiabilidad propuesta se obtiene *sin coste adicional de inferencia* (reutiliza las probabilidades que el modelo ya produce), evitando el gasto computacional de métodos que exigen múltiples generaciones o modelos auxiliares. Esta frugalidad favorece la accesibilidad del sistema en entornos con recursos limitados.

5.10 Impacto, agentes implicados y viabilidad

Los agentes implicados en un despliegue del sistema son el radiólogo (usuario y decisor), el servicio de radiología (que gestiona la carga de trabajo), el paciente (beneficiario último de una lectura más segura) y el equipo técnico responsable de la calibración y el mantenimiento. El impacto potencial es triple. En el plano asistencial, un priorizador de revisión bien calibrado permite concentrar la atención

del radiólogo en los informes de mayor riesgo, mitigando la presión asistencial sin comprometer la seguridad. En el plano de la seguridad del paciente, la comunicación explícita y honesta de la fiabilidad (incluida la advertencia sobre las omisiones) reduce el riesgo de una confianza injustificada en la salida automática. Y en el plano científico-técnico, el trabajo aporta una metodología de auditoría de la fiabilidad reutilizable para otros modelos y dominios.

En cuanto a la viabilidad, el enfoque es deliberadamente frugal: todos los modelos se ejecutan cuantizados en una única tarjeta gráfica de consumo, sin infraestructura especializada, y la señal de confianza no incurre en coste de inferencia adicional. El principal recurso consumido es el tiempo de cómputo de la extracción de señales y el etiquetado, mitigado mediante procesos reanudables. Esta frugalidad hace el sistema económicamente viable y accesible en entornos con recursos limitados, y compatible con su integración como módulo asistivo en flujos de trabajo existentes.

5.11 Discusión y análisis de los resultados

Los resultados dibujan una imagen coherente. La explicación visual de estos modelos es *fiel y está anclada*, lo que valida su uso como puntero de "dónde mirar"; pero la fiabilidad no se lee en la forma de la explicación (ni en el mapa de calor, ni en el *lift* objetivo, ni en las cajas entrenadas del propio modelo) sino en la incertidumbre de la decisión, y de forma robusta solo para las alucinaciones. Esta señal, una vez depurada del token de apertura, resulta *simple, agnóstica al modelo y disponible en inferencia*, y (a diferencia de lo que sugería el único generador inicial) *se transfiere fuera de distribución* cuando el generador es de calidad suficiente. Que un modelo mejor mantenga la señal fuera de distribución (0,81) mientras el débil la pierde (0,61) indica que el problema no es el método sino el generador que, sin datos del dominio, alucina con confianza. La exploración de señales adicionales (entropía, verosimilitud, auto-consistencia, dependencia de imagen) mostró que ninguna mejora de forma consistente en los tres datasets: son específicas de modelo o de dominio, por lo que la fórmula final privilegia la *simplicidad robusta* de una única señal frente a un combinado sobreajustado.

Las omisiones quedan como problema de sensibilidad del generador, detectable solo en parte desde sus propias señales y por otra vía (mejor generador o anclaje explícito). Como aportación transversal, de carácter metodológico, conviene subrayar que repetidamente señales de apariencia fuerte (el máximo de atención, la entropía cruda confundida por la longitud, la relación *lift*–acierto, las propias cajas del modelo) resultaron artefactos que solo un control cuidadoso de confusores y la vali-

dación contra referencias objetivas revelaron; en este dominio, *validar contra verdad objetiva es imprescindible.*

En relación con la literatura, estos resultados matizan y extienden el conocimiento previo. Confirman, por un lado, la intuición de que la incertidumbre del modelo es un mejor predictor de la alucinación que sus explicaciones visuales, en línea con los métodos de auto-consistencia y de estimación de incertidumbre desarrollados para modelos de lenguaje generales; pero aportan, por otro, tres elementos propios del dominio radiológico que la literatura no había establecido de forma conjunta: la disociación cuantitativa entre alucinaciones detectables y omisiones que no lo son, la robustez cruzada de la señal entre modelos y dominios (con la identificación del generador débil como causa de la degradación fuera de distribución) y la constatación, con las cajas de anclaje del propio modelo, de que ni siquiera una explicación entrenada y plausible predice el acierto. El valor práctico de estos hallazgos es directo: indican que un sistema de ayuda al radiólogo debe construir su señal de confianza sobre la incertidumbre de la decisión, comunicar honestamente su alcance (que no cubre las omisiones) y calibrarse por modelo antes de su despliegue.

Finalmente, procede señalar las limitaciones: MAIRA-2 fue entrenado con PadChest, por lo que su evaluación in-distribution puede incluir solape train–test (mitigado usando Open-I, ajeno a su entrenamiento, como prueba fuera de distribución); el número de alucinaciones por celda es reducido, lo que ensancha los intervalos de confianza; y el beneficio clínico real de presentar informe, anclaje y confianza al radiólogo requeriría un estudio prospectivo de lectura, que se propone como trabajo futuro.

En síntesis, los resultados muestran que, en los modelos y dominios evaluados, la explicación visual puede aportar información sobre el anclaje espacial de la generación, pero no constituye una señal fiable de corrección. En cambio, la incertidumbre generativa, medida mediante la probabilidad mínima de contenido, ofrece una señal simple y transferible para priorizar la revisión de posibles alucinaciones, aunque no resuelve de forma completa la detección de omisiones.

Capítulo 6

Conclusiones

Este capítulo recupera los objetivos planteados y valora su cumplimiento, recorre las limitaciones y la prospectiva, y cierra con una reflexión personal.

Respecto a los objetivos específicos, todos se han cumplido. Se ha revisado el estado del arte (Cap. 3), situando la aportación en el hueco de la explicabilidad validada de los MLLM de radiografía de tórax. Se ha diseñado e implementado un generador multimodal propio con destilación de conocimiento y un marco reutilizable de explicabilidad. Se ha cuantificado de forma objetiva el anclaje clínico de la atención contra anotaciones reales de localización (lift global 3,03). Y se ha determinado la capacidad de la explicabilidad y la incertidumbre para detectar errores, con un resultado matizado y sólido: la morfología de la explicación no predice la fiabilidad (lo que se confirma por triple vía, incluidas las cajas de anclaje del propio modelo), pero la incertidumbre de la decisión detecta las alucinaciones (AUC 0,90 tras depurar el token de apertura), no las omisiones, que solo se captan de forma parcial.

En cuanto al objetivo general (investigar qué señales internas de los MLLM permiten estimar de forma fiable la corrección de los informes, comparando el valor de la explicabilidad visual y de la incertidumbre generativa), se ha alcanzado: en los modelos y dominios evaluados, las explicaciones son fieles y están ancladas, pero los resultados indican que la fiabilidad se explica mejor por la incertidumbre de la decisión que por la morfología del mapa de calor. Es más, dicha señal ha demostrado ser agnóstica al modelo y robusta al dominio: validada en un diseño 2×2 (dos generadores $\times$ dos dominios), se transfiere a un segundo modelo del estado del arte (MAIRA-2) y se mantiene *fuera de distribución* para el generador de calidad suficiente (AUC 0,80–0,81), mientras que la degradación observada se atribuye al generador débil, no al método. La contribución puede sintetizarse en tres elementos:

- la validación objetiva del anclaje de la atención de un MLLM de CXR frente a anotaciones reales de localización;
- la demostración, por triple vía, de que la explicación visual no predice la fiabilidad del informe, ni siquiera cuando se emplean las cajas de anclaje entrenadas del propio modelo;
- la propuesta y validación cruzada de una señal de incertidumbre para la detección de alucinaciones, simple, agnóstica al modelo y calibrada en una confianza por informe, junto con su traducción clínica en una demostración interactiva.

Como aportación metodológica menor pero de valor práctico, se documenta que *excluir el token de apertura del informe* mejora de forma sistemática la señal de incertidumbre.

El significado de conjunto de estas conclusiones puede resumirse en una idea: en los modelos y dominios estudiados, la fiabilidad de un informe se explica mejor por *lo seguro que está* el modelo al decidir que por *lo que muestra* en su explicación visual, y esa seguridad resultó, en este trabajo, cuantificable, transferible entre modelos y calibrable para su uso clínico, siempre que se comunique con honestidad su alcance. Este desplazamiento del foco, de la explicación a la incertidumbre, es la contribución conceptual central del trabajo, y sugiere implicaciones para el diseño de sistemas de ayuda a la decisión: la evidencia visual parece más apropiada como *apoyo a la localización* que como garantía de acierto, y la confianza podría construirse sobre la señal interna del modelo antes que sobre la forma de su explicación, si bien confirmar el alcance de esta implicación fuera de los modelos y dominios aquí evaluados requeriría más validación (Sección 6.3).

6.1 Respuesta a las preguntas de investigación

Tabla 6.1: Resumen de las cuatro preguntas de investigación (Capítulo 1) e hipótesis asociadas (H1–H4, Sección 4.2) frente a la evidencia obtenida.

Pregunta	Resultado	Evidencia clave
PI1: ¿anclaje clínico?	Confirmada	Lift global 3,03; *pointing-game* 0,38
PI2: ¿morfología predice fiabilidad?	Refutada	AUC 0,54 (n.s.); confirmado por triple vía
PI3: ¿incertidumbre detecta errores?	Confirmada (asimétrica)	AUC 0,80–0,90 alucinaciones; parcial en omisiones
PI4: ¿agnóstica y robusta?	Confirmada con matiz	Transfiere a MAIRA-2; falla solo en generador débil OOD

Recapitulando las cuatro preguntas planteadas en el Capítulo 1: en cuanto a **PI1**, la atención está clínicamente anclada (lift 3,03; tres veces el azar en el *pointing-game*), lo que valida su uso como puntero de *dónde* mira el modelo. Respecto a **PI2**, la morfología de la explicación *no* predice la fiabilidad: ni el mapa de calor de atención, ni el *lift* objetivo, ni las cajas de anclaje entrenadas del propio modelo (que localizan las alucinaciones con la misma plausibilidad que los hallazgos reales) separan el acierto del error. En cuanto a **PI3**, la incertidumbre de la decisión sí detecta los errores, pero de forma *asimétrica*: robusta para las alucinaciones (AUC 0,80–0,90) y solo parcial para las omisiones, que tienden a situarse cerca del umbral. Y sobre **PI4**, la señal es agnóstica al modelo y robusta al dominio: se transfiere a un segundo generador y se mantiene fuera de distribución para un generador de calidad suficiente, degradándose solo con un generador débil que, sin datos del dominio, alucina con confianza. En conjunto, las cuatro preguntas quedan respondidas de forma coherente y con matices respaldados por la evidencia.

6.2 Limitaciones

Algunas limitaciones de las versiones preliminares se han *resuelto* en el propio trabajo: la dependencia de un único juez se ha mitigado con tres fuentes de verdad concordantes; la de un único modelo, validando en dos generadores; y la de un único dominio, con la réplica en PadChest-GR. Persisten, no obstante, limitaciones reales. El número de alucinaciones por celda es reducido (entre 12 y 110), lo que ensancha los intervalos de confianza. La evaluación *in-distribution* de MAIRA-2 sobre PadChest puede incluir solape train–test, al haber sido entrenado con ese corpus; se

mitiga usando Open-I (ajeno a su entrenamiento) como prueba fuera de distribución, pero conviene señalarlo. La detección de omisiones es solo parcial: son errores de sensibilidad del generador, no siempre acompañados de incertidumbre. Metodológicamente, varias señales de forma resultaron engañosas (el máximo de atención, la entropía confundida con la longitud, la relación *lift*–acierto), lo que obligó a un control cuidadoso de confusores. Por último, el beneficio clínico no se ha demostrado empíricamente: requeriría un estudio prospectivo de lectura.

Varias de estas limitaciones tienen origen en las condiciones materiales del proyecto. El acceso a datos clínicos de mayor tamaño estuvo restringido: MIMIC-CXR, el corpus narrativo de referencia en el área, exige credenciales de PhysioNet no disponibles para este trabajo (Sección 4.1), lo que obligó a construir el diseño experimental sobre conjuntos abiertos de menor tamaño (Open-I, NIH ChestX-ray8, PadChest-GR) y es, en buena medida, la causa directa del reducido número de alucinaciones por celda señalado más arriba. El cómputo también estuvo acotado a una única GPU de consumo, lo que impuso ejecutar los modelos del estado del arte cuantizados a 8 bits (sin comparación frente a precisión completa) y limitó la escala y el número de repeticiones de las ablaciones del modelo propio (Sección 4.4). Ninguna de estas restricciones invalida los resultados, que se sostienen sobre tres fuentes de verdad y dos réplicas independientes, pero sí marca el techo de precisión alcanzable con los recursos disponibles y es la razón principal de la primera línea de prospectiva (consolidación estadística).

6.3 Prospectiva

El trabajo abre varias líneas de continuación, que se ordenan de la más inmediata a la más ambiciosa.

Consolidación estadística. La primera línea es ampliar la muestra de imágenes por celda del diseño, dado que el número de alucinaciones (el factor que limita la precisión de la estimación) es reducido; ampliarlo estrecharía los intervalos de confianza. En la misma dirección, añadir más generadores (por ejemplo, modelos con razonamiento por agentes o de otra familia) y más dominios reforzaría la generalidad de la conclusión sobre la robustez de la señal.

Cierre de la duda del solape. La evaluación *in-distribution* de MAIRA-2 sobre PadChest podría incluir solape con su entrenamiento; evaluar el modelo fuera de distribución en dominios verdaderamente ajenos y sin intersección con su corpus cerraría definitivamente esta cuestión.

Detección de omisiones. Las omisiones son el error que la incertidumbre no capta de forma fiable, por tratarse de fallos confiados de sensibilidad. Abordarlas requeriría vías complementarias: mejorar la sensibilidad del propio generador, emplear un anclaje explícito que "obligue" a mirar regiones sospechosas, o recurrir a la autoconsistencia semántica entre múltiples muestras, que podría revelar la inestabilidad de un informe incompleto.

De la detección a la prevención. Más allá de detectar la alucinación tras generarla, la señal de incertidumbre podría integrarse en el propio proceso de *decodificación* para prevenir la fabricación (por ejemplo, penalizando las continuaciones de baja confianza o solicitando evidencia adicional), convirtiendo el sistema de un detector *a posteriori* en una salvaguarda *a priori*.

Validación clínica. Finalmente, la línea de mayor calado es un estudio de lectura prospectivo con radiólogos que mida el beneficio real de presentar informe, anclaje y confianza, cuantificando su efecto sobre la precisión diagnóstica, el tiempo de lectura y el riesgo de sesgo de automatización. Solo un estudio de este tipo puede demostrar el valor clínico que este trabajo fundamenta pero no llega a probar, y sería el paso natural hacia una eventual integración del sistema como módulo asistivo en el flujo de trabajo radiológico.

6.4 Mejoras futuras del sistema

Las líneas anteriores extienden la investigación; las que siguen extienden el sistema en un sentido de ingeniería, orientado a acercarlo a un entorno de uso real.

Ampliación del catálogo de hallazgos. El etiquetado objetivo se restringe a los hallazgos *agudos* más frecuentes y a las ocho patologías con caja de NIH ChestX-ray8. Extender el marco a un catálogo más amplio (hallazgos crónicos, óseos o de dispositivos) exigiría nuevas fuentes de verdad, pero ampliaría la cobertura clínica real del sistema.

Integración con el flujo de trabajo radiológico. La demostración actual es un prototipo *standalone*; su valor práctico aumentaría integrándola como módulo dentro del visor de imágenes o del sistema de información radiológica (RIS/PACS) del centro, de modo que el informe, el anclaje y la confianza aparezcan directamente en la estación de lectura, sin cambiar la herramienta que el radiólogo ya usa.

Optimización de la latencia de inferencia. El sistema se ejecuta hoy cuantizado a 8 bits en una única GPU de consumo (Sección 4.7); técnicas adicionales de optimización (cuantización a 4 bits, motores de inferencia especializados o destilación del propio generador) reducirían la latencia y el coste de despliegue, acercando el sistema a un uso en tiempo real durante la lectura.

Ampliación a otras modalidades. El marco de explicabilidad e incertidumbre (agnóstico al generador por construcción) no depende de particularidades de la radiografía de tórax; extenderlo a otras modalidades con MLLM propios (tomografía computarizada, resonancia magnética, mamografía) permitiría comprobar si la conclusión central del trabajo (que la fiabilidad reside en la incertidumbre y no en la explicación visual) se sostiene fuera del dominio aquí estudiado.

Modelos de mayor escala y capacidad de imagen. Este trabajo se ha ejecutado sobre generadores de 7 mil millones de parámetros y con la resolución de entrada que cada uno define por diseño, condicionado por el hardware de consumo disponible (Sección 6.2). Investigar con modelos de mayor potencia y con mayor capacidad de procesamiento de imagen (más tokens visuales, mayor resolución de entrada) permitiría estudiar si la morfología del mapa de calor, que en este trabajo no logró predecir la fiabilidad, se comporta de forma distinta en arquitecturas más grandes y con una representación visual más rica, cerrando una pregunta que la limitación de recursos deja abierta.

Consolidación de la portabilidad. El trabajo ya distribuye la memoria y las de-

mostraciones mediante imágenes Docker reproducibles (Anexo de organización del repositorio); una línea natural es exponer el sistema de análisis como una API desplegable en la nube, desacoplada de la interfaz Gradio actual, para que otros equipos puedan integrarlo en sus propias herramientas sin depender de esta implementación concreta.

6.5 Consideraciones finales

Considero que el resultado final de esta investigación fue satisfactorio, no solo por lo logrado al poder "acotar" con una métrica un umbral de alucinaciones (con el beneficio añadido de que muchas omisiones se sitúan precisamente en ese umbral), sino por todo el aprendizaje que ha conllevado.

Ese aprendizaje me ha enseñado, incluso creyendo que ya estaba familiarizado con el método científico, lo que de verdad significa el rigor en el control de confusores tras varios "falsos positivos". Cuántas veces habré creído tener algo interesante entre manos, para que la siguiente batería de pruebas mostrara que la hipótesis no se sostenía. Pero esa negación de la idea inicial del TFM no fue el final del proyecto, sino el paso de una intuición (los mapas de calor) a su refutación con evidencia. He aprendido a trabajar con MLLM de gran escala, con cuantización y con extracción de señales a escala; a comunicar un resultado negativo con la misma solidez que uno positivo; y, finalmente, a llegar a algo que sí era capaz de aportar.

Si hoy empezara de nuevo (no con el conocimiento adquirido, sino con las aptitudes desarrolladas durante el Máster y el propio TFM) seguramente no habría cambiado el resultado, pues se habrían hecho las mismas pruebas, pero las habría hecho bien a la primera, con más rigor científico y sin dejarme llevar por pequeñas victorias sesgadas que acabaron en sobretrabajo antes de comprobar si realmente eran buenos indicios. Y, sobre todo, habría empezado el procesamiento de datos mucho antes, incluso mientras todavía planteaba las ideas. Me habría encantado poder validar las hipótesis con más datos, pero el tiempo disponible y el hardware del equipo con el que se realizó el trabajo lo complicaron.

No puedo terminar este trabajo sin expresar mi deseo de que la asistencia por IA en radiología evolucione hacia sistemas honestos sobre su propia incertidumbre, y no solo hacia modelos cada vez más grandes (y, en muchos casos, aún más caja negra), y de que se apliquen a los MLLM todos los avances de la IA explicable clásica, como los vistos en la asignatura de XAI del Máster. Espero que esta pequeña contribución sea un paso, por modesto que sea, en esa dirección.

Bibliografía

Abnar, S., & Zuidema, W. (2020). Quantifying Attention Flow in Transformers. *Proceedings of ACL*.

Alayrac, J.-B., Donahue, J., Luc, P., Miech, A., et al. (2022). Flamingo: a Visual Language Model for Few-Shot Learning. *Advances in Neural Information Processing Systems (NeurIPS)*.

Bannur, S., Bouzid, K., Castro, D. C., Schwaighofer, A., Thieme, A., Bond-Taylor, S., Ilse, M., Pérez-García, F., Salvatelli, V., Sharma, H., Meissen, F., Ranjit, M., Srivastav, S., Gong, J., Codella, N. C. F., Falck, F., Oktay, O., Lungren, M. P., Wetscherek, M. T., ... Hyland, S. L. (2024). MAIRA-2: Grounded Radiology Report Generation. *arXiv preprint arXiv:2406.04449*.

Boecking, B., Usuyama, N., Bannur, S., Castro, D. C., et al. (2022). Making the Most of Text Semantics to Improve Biomedical Vision–Language Processing. *Proceedings of ECCV*.

Castro, D. C., Bustos, A., Bannur, S., Hyland, S. L., Bouzid, K., Wetscherek, M. T., Sánchez-Valverde, M. D., Jaques-Pérez, L., Pérez-Rodríguez, L., Takeda, K., Salinas, J. M., Alvarez-Valle, J., Galant Herrero, J., & Pertusa, A. (2025). PadChest-GR: A Bilingual Chest X-Ray Dataset for Grounded Radiology Report Generation. *NEJM AI*, *2*(7). https://doi.org/10.1056/AIdbp2401120

Chefer, H., Gur, S., & Wolf, L. (2021). Transformer Interpretability Beyond Attention Visualization. *Proceedings of CVPR*.

Demner-Fushman, D., Kohli, M. D., Rosenman, M. B., Shooshan, S. E., Rodriguez, L., Antani, S., Thoma, G. R., & McDonald, C. J. (2016). Preparing a Collection of Radiology Examinations for Distribution and Retrieval. *Journal of the American Medical Informatics Association (JAMIA)*, *23*(2), 304-310.

DeYoung, J., Jain, S., Rajani, N. F., Lehman, E., Xiong, C., Socher, R., & Wallace, B. C. (2020). ERASER: A Benchmark to Evaluate Rationalized NLP Models. *Proceedings of ACL*.

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., et al. (2021). An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. *International Conference on Learning Representations (ICLR)*.

Ghassemi, M., Oakden-Rayner, L., & Beam, A. L. (2021). The False Hope of Current Approaches to Explainable Artificial Intelligence in Health Care. *The Lancet Digital Health*, *3*(11), e745-e750.

Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On Calibration of Modern Neural Networks. *Proceedings of the International Conference on Machine Learning (ICML)*.

Jain, S., Agrawal, A., Saporta, A., Truong, S. Q. H., Duong, D. N., Bui, T., Chambon, P., Zhang, Y., Lungren, M. P., Ng, A. Y., Langlotz, C. P., & Rajpurkar, P. (2021). RadGraph: Extracting Clinical Entities and Relations from Radiology Reports. *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*.

Jain, S., & Wallace, B. C. (2019). Attention is not Explanation. *Proceedings of NAACL-HLT*.

Ji, Z., Lee, N., Frieske, R., Yu, T., et al. (2023). Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, *55*(12), 1-38.

Kadavath, S., Conerly, T., Askell, A., Henighan, T., et al. (2022). Language Models (Mostly) Know What They Know. *arXiv preprint arXiv:2207.05221*.

Khovanova, D., Vasilev, Y., Vladzymyrskyy, A., Omelyanskaya, O., Pamova, A., & Arzamasov, K. (2025). A comparative accuracy study of multimodal LLMs, VLM and agent-based framework for pulmonary nodule detection on chest radiographs. *Frontiers in Digital Health*, *7*, 1674835. https://doi.org/10.3389/fdgth.2025.1674835

Kuhn, L., Gal, Y., & Farquhar, S. (2023). Semantic Uncertainty: Linguistic Invariances for Uncertainty Estimation in Natural Language Generation. *Proceedings of ICLR*.

Li, J., Li, D., Savarese, S., & Hoi, S. (2023). BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models. *Proceedings of the International Conference on Machine Learning (ICML)*.

Lin, C.-Y. (2004). ROUGE: A Package for Automatic Evaluation of Summaries. *Text Summarization Branches Out (ACL Workshop)*.

Liu, H., Li, C., Wu, Q., & Lee, Y. J. (2023). Visual Instruction Tuning. *Advances in Neural Information Processing Systems (NeurIPS)*.

Manakul, P., Liusie, A., & Gales, M. J. F. (2023). SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models. *Proceedings of EMNLP*.

Pérez-García, F., Sharma, H., Bond-Taylor, S., et al. (2024). RAD-DINO: Exploring Scalable Medical Image Encoders Beyond Text Supervision. *arXiv preprint arXiv:2401.10815*.

Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., et al. (2021). Learning Transferable Visual Models From Natural Language Supervision. *Proceedings of the International Conference on Machine Learning (ICML)*.

Smit, A., Jain, S., Rajpurkar, P., Pareek, A., Ng, A. Y., & Lungren, M. P. (2020). CheXbert: Combining Automatic Labelers and Expert Annotations for Accurate Radiology Report Labeling Using BERT. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 1500-1519.

Sundararajan, M., Taly, A., & Yan, Q. (2017). Axiomatic Attribution for Deep Networks. *Proceedings of ICML*.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention is All you Need. *Advances in Neural Information Processing Systems (NeurIPS)*.

Vinyals, O., Toshev, A., Bengio, S., & Erhan, D. (2015). Show and Tell: A Neural Image Caption Generator. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 3156-3164.

Wang, X., Peng, Y., Lu, L., Lu, Z., Bagheri, M., & Summers, R. M. (2017). ChestX-ray8: Hospital-scale Chest X-ray Database and Benchmarks on Weakly-Supervised Classification and Localization of Common Thorax Diseases. *Proceedings of CVPR*.

Wiegreffe, S., & Pinter, Y. (2019). Attention is not not Explanation. *Proceedings of EMNLP-IJCNLP*.

Xu, K., Ba, J., Kiros, R., Cho, K., Courville, A., Salakhutdinov, R., Zemel, R., & Bengio, Y. (2015). Show, Attend and Tell: Neural Image Caption Generation with Visual Attention. *Proceedings of the International Conference on Machine Learning (ICML)*, 2048-2057.

Zambrano Chaves, J. M., Huang, S.-C., Xu, Y., Xu, H., Usuyama, N., Zhang, S., Wang, F., Xie, Y., Khademi, M., Yang, Z., Awadalla, H., Gong, J., Hu, H., Yang, J., Li, C., Gao, J., Gu, Y., Wong, C., Wei, M., ... Poon, H. (2025). A clinically accessible small multimodal radiology model and evaluation metric for chest X-ray findings. *Nature Communications*, *16*, 3108.

Zhang, S., Sambara, S., Banerjee, O., Acosta, J., Fahrner, L. J., & Rajpurkar, P. (2025). RadFlag: A Black-Box Hallucination Detection Method for Medical Vision Language Models. *Proceedings of the 4th Machine Learning for Health Symposium*, *259*, 1087-1103.

Apéndice A

Anexos: detalles de reproducibilidad

Este anexo recoge los detalles técnicos que permiten reproducir los experimentos. No forma parte de la evaluación pero documenta las decisiones de implementación.

A.1 Entornos de ejecución

Los experimentos se ejecutan en Python sobre dos entornos aislados, dado que los dos generadores exigen versiones incompatibles de la biblioteca de *transformers*. El entorno de LLaVA-Rad emplea `transformers 4.31` y `torch 2.0`; el de MAIRA-2, `transformers 4.46` y `torch 2.1`. Ambos generadores se cargan con cuantización a 8 bits mediante `bitsandbytes`, lo que permite ejecutar modelos de 7 mil millones de parámetros en una única tarjeta gráfica de 12 GB de memoria.

A.2 Extracción de señales

Para cada imagen se realiza una pasada que produce: (i) el informe voraz junto con las probabilidades y entropías por token; (ii) $K = 4$ muestras estocásticas para la auto-consistencia; y (iii) una generación con la imagen en blanco para la dependencia de imagen. En el subconjunto con mapa de calor se añade una pasada con salida de atención. La extracción es resumible: los resultados se escriben incrementalmente en formato JSONL, de modo que un proceso interrumpido se reanuda saltando los identificadores ya procesados. El rendimiento es de aproximadamente 27–42 segundos por imagen según el modelo.

A.3 Hiperparámetros de generación

El informe principal se genera de forma voraz (*greedy*, sin muestreo) con un máximo de 60–120 tokens nuevos. Las K muestras de auto-consistencia se generan con muestreo estocástico (temperatura 0,8, *top-p* 0,95). La generación con imagen en blanco emplea una imagen de valor cero del mismo tamaño. Para MAIRA-2, el anclaje se obtiene activando la generación con cajas y analizando la secuencia resultante en frases y coordenadas normalizadas.

A.4 Acceso a los datos y etiquetado

Se emplean tres conjuntos de acceso libre: Open-I / Indiana University (informes y términos MeSH), NIH ChestX-ray8 (cajas de ocho patologías) y un subconjunto de PadChest-GR (hallazgos presentes/ausentes y cajas). El etiquetado por juez se ejecuta de forma reproducible y con escritura incremental, con una rúbrica fija que restringe la evaluación a los hallazgos agudos significativos.

A.5 Métodos estadísticos

La capacidad discriminativa se mide con el área bajo la curva ROC, calculada mediante el estadístico de Mann–Whitney sobre rangos para garantizar reproducibilidad. Los intervalos de confianza se estiman por *bootstrap* estratificado (2000 remuestreos) y la significancia frente al azar, con tests de permutación. La calibración se evalúa por bandas de riesgo definidas sobre cuartiles de la distribución de los informes correctos. Todo el control de confusores (longitud, posición del token, tipo de mapa de calor) se realiza mediante residualización o comparaciones emparejadas.

A.6 Hardware

Todos los experimentos se ejecutan localmente en una tarjeta gráfica NVIDIA de gama de consumo con 12 GB de memoria, lo que demuestra la viabilidad del enfoque sin infraestructura especializada.

Apéndice B

Anexos: manual de usuario de la demostración

Este anexo describe el uso de la demostración interactiva desarrollada, que materializa el sistema de informe, anclaje y confianza. Se proporcionan dos aplicaciones equivalentes, una por generador, dado que ambos modelos no caben simultáneamente en la memoria de una única tarjeta gráfica de 12 GB.

B.1 Puesta en marcha

Cada aplicación se lanza de forma independiente desde su entorno correspondiente. La aplicación de LLaVA-Rad se sirve en un puerto local y muestra el anclaje mediante mapa de calor; la de MAIRA-2, en otro puerto, muestra el anclaje mediante cajas generadas por el propio modelo. Al arrancar, la aplicación carga el modelo cuantizado (unos treinta segundos) y queda accesible desde un navegador web en la dirección local indicada. Alternativamente, cada aplicación puede lanzarse mediante la imagen Docker correspondiente (Anexo de organización del repositorio), lo que evita instalar manualmente el entorno Python y sus versiones fijadas; en ese caso, los pesos del modelo se descargan automáticamente en el primer arranque.

B.2 Interfaz y flujo de trabajo

La interfaz se organiza en tres paneles, alineados con la propuesta del trabajo:

- **Panel izquierdo: informe.** Muestra la radiografía cargada y, debajo, el in-

forme generado por el modelo. El usuario puede subir su propia imagen o seleccionar uno de los ejemplos incluidos, que además presentan el *veredicto real del radiólogo* para comparar.

- **Panel central: anclaje.** Muestra *dónde* mira el modelo: el mapa de calor de atención (LLaVA-Rad) o las cajas de localización (MAIRA-2). Sirve como evidencia visual de la afirmación, no como prueba de acierto.
- **Panel derecho: confianza.** Muestra el semáforo calibrado: una banda de verde a rojo con un marcador en la posición de la puntuación del informe, la banda de riesgo correspondiente y una tabla con la probabilidad de alucinación de cada banda. Incluye la advertencia de que el verde indica baja probabilidad de alucinación pero no garantiza la ausencia de omisiones.

El flujo de uso previsto es: cargar la imagen, pulsar *Analizar* y leer el informe consultando el anclaje como apoyo y el semáforo para priorizar la revisión de los casos en zona roja. Las Figuras B.1 y B.2 muestran las dos aplicaciones en ejecución sobre un caso real de cada conjunto.

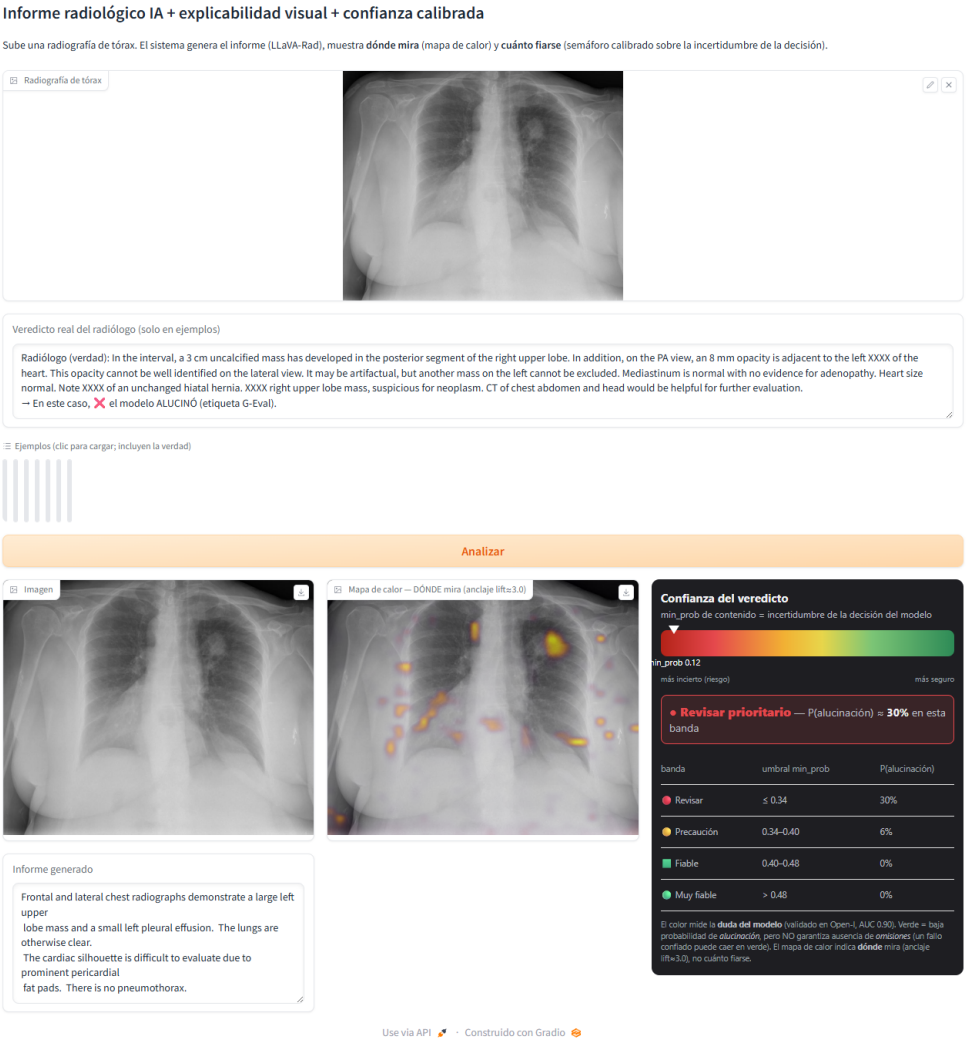


Figura B.1: Aplicación de LLaVA-Rad en ejecución sobre un caso real de Open-I. El modelo alucina una masa pulmonar inexistente (compárese con el veredicto real del radiólogo, panel superior); el semáforo lo detecta correctamente y lo sitúa en zona roja (min_prob 0,11, P(alucinación) $\approx$ 30 %).

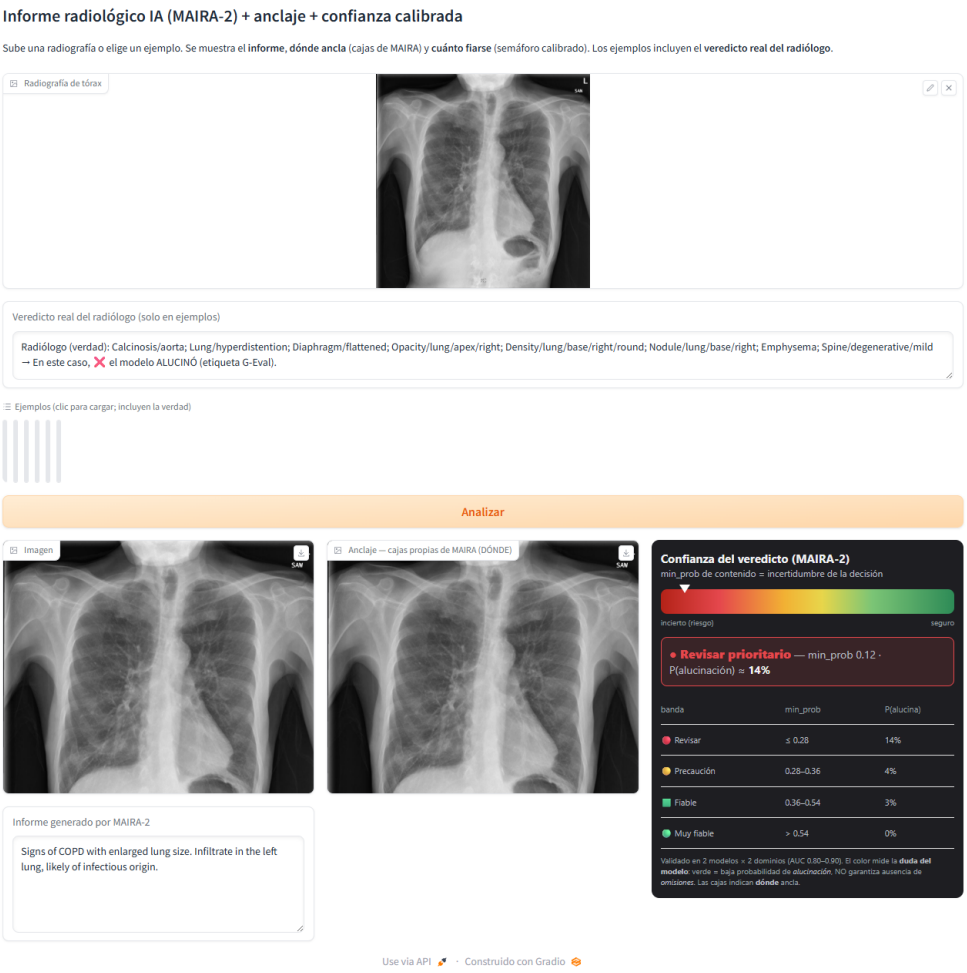


Figura B.2: Aplicación de MAIRA-2 en ejecución sobre un caso real de PadChest-GR. El modelo también alucina en este caso; el semáforo lo sitúa igualmente en zona roja (min_prob 0,12, P(alucinación) $\approx$ 14 %). El panel de anclaje muestra la imagen con las cajas propias del modelo cuando las genera.

B.3 Instalación y ejecución con Docker (paso a paso)

Esta sección explica cómo poner en marcha ambas demostraciones en un ordenador que no tiene instalado ni Python ni las bibliotecas del proyecto (por ejemplo, el equipo de un profesor evaluador), usando únicamente Docker. No se requiere ningún conocimiento de programación; basta con ejecutar los comandos indicados en una terminal.

Requisitos. Un equipo con Docker Desktop instalado (gratuito, disponible para Windows, macOS y Linux desde https://www.docker.com/products/docker-desktop/) y, para las demostraciones (no para compilar la memoria), una tarjeta gráfica NVIDIA con al menos 12 GB de memoria y el *NVIDIA Container Toolkit* instalado, que permite a Docker acceder a la GPU. Sin GPU es posible, aun así, compilar la memoria en PDF con la primera imagen descrita a continuación.

Paso 1: obtener el código. Descomprimir el paquete del proyecto (o clonar el repositorio) en cualquier carpeta local, y abrir una terminal en la carpeta raíz del proyecto (la que contiene la carpeta `docker/`).

Paso 2: construir las imágenes. Cada imagen se construye una única vez; la construcción tarda varios minutos porque descarga las bibliotecas necesarias, pero no requiere ninguna interacción:

```
docker build -t tfm-llavarad -f docker/Dockerfile.llavarad .
docker build -t tfm-maira2   -f docker/Dockerfile.maira2   .
```

Paso 3: lanzar una demostración. Las dos aplicaciones no caben a la vez en una GPU de 12 GB, por lo que se lanzan una cada vez:

```
docker run --rm --gpus all -p 7860:7860 \
  -v hf_cache_llavarad:/hf_cache tfm-llavarad
docker run --rm --gpus all -p 7862:7862 \
  -v hf_cache_maira2:/hf_cache tfm-maira2
```

La primera vez que se ejecuta cada comando, el contenedor descarga automáticamente los pesos del modelo desde *Hugging Face Hub* (varios minutos, según la conexión)

y los conserva en el volumen indicado, de modo que los arranques posteriores son mucho más rápidos. El acceso al modelo `microsoft/maira-2` exige haber aceptado su licencia en Hugging Face con la cuenta cuyo token se utilice; el contenedor solicitará este dato la primera vez si no está ya configurado mediante la variable de entorno `HF_TOKEN`.

Paso 4: abrir la demostración. Cuando la terminal muestra que el servidor está listo, basta con abrir un navegador web en http://127.0.0.1:7860 (LLaVA-Rad) o http://127.0.0.1:7862 (MAIRA-2) y usar la interfaz descrita en la sección anterior. Para detener la aplicación es suficiente con cerrar la terminal o pulsar `Ctrl+C`.

Compilar la memoria sin instalar LaTeX. De forma análoga, la memoria en PDF puede regenerarse sin instalar ninguna distribución LaTeX localmente:

```
docker build -t tfm-latex -f docker/Dockerfile.latex .
docker run --rm \
  -v "RUTA_ABSOLUTA_AL_PROYECTO/memoria:/memoria" tfm-latex
```

sustituyendo `RUTA_ABSOLUTA_AL_PROYECTO` por la ruta local del proyecto; el PDF resultante se escribe directamente en la carpeta `memoria/`. Los detalles adicionales (versiones fijadas, `docker compose` como alternativa) se documentan en el Anexo de organización del repositorio.

B.4 Interpretación de la salida

Un informe en zona verde indica que el modelo ha generado su veredicto con alta confianza y baja probabilidad de alucinación; el radiólogo puede revisarlo con menor prioridad, sin olvidar la posibilidad de una omisión. Un informe en zona roja señala alta incertidumbre y una probabilidad de alucinación elevada; debe revisarse de forma prioritaria. Las bandas intermedias gradúan esa prioridad. En todo caso, la decisión final corresponde siempre al facultativo.

Apéndice C

Anexos: organización del repositorio

El código del proyecto se organiza de forma modular para separar responsabilidades y facilitar la reproducibilidad, siguiendo la arquitectura por capas descrita en el Capítulo 4.

C.1 Estructura

El módulo de datos agrupa la ingesta y el preprocesado de los conjuntos empleados. El módulo de modelos contiene la arquitectura del generador propio (codificador visual, decodificador con atención cruzada y su ensamblaje). El módulo de explicabilidad implementa la extracción del mapa de calor, las métricas de anclaje y la evaluación de fidelidad por oclusión. El módulo de entrenamiento orquesta las dos etapas (alineamiento contrastivo y ajuste generativo). Los scripts de extracción producen, para cada modelo y conjunto, los ficheros de señales en formato JSONL reanudable, y los scripts de análisis calculan las métricas de detección y calibración. Finalmente, la demostración contiene las dos aplicaciones interactivas.

C.2 Reproducibilidad

Cada experimento se acompaña de sus scripts y de los ficheros intermedios (señales, etiquetas, figuras), de modo que los resultados de la memoria pueden regenerarse. Los procesos largos se ejecutan de forma reanudable, escribiendo su salida de forma incremental, lo que permite reanudarlos tras una interrupción sin repetir el trabajo ya realizado.

C.3 Contenerización y portabilidad

Para evitar que la reproducibilidad dependa de instalar manualmente una distribución LaTeX o los dos entornos Python de inferencia (cada uno con una combinación de versiones específica y ya depurada de conflictos entre *bibliotecas*), el repositorio incluye tres imágenes Docker independientes. La primera compila la memoria (`pdflatex` + `biber` + `biblatex-apa` + TikZ) sin requerir ninguna instalación local de LaTeX; basta con montar el directorio `memoria/` como volumen. Las otras dos reproducen, respectivamente, el entorno de LLaVA-Rad y el de MAIRA-2 empleados en las demostraciones (Anexo de manual de usuario), fijando las mismas versiones validadas en el Anexo de reproducibilidad (incluida la combinación específica de `gradio 3.50.2` con `pydantic 1.x` necesaria para evitar la incompatibilidad con `pydantic 2` presente en versiones más recientes de Gradio). Los pesos de los modelos no se empaquetan en las imágenes, que quedarían así de decenas de gigabytes: se descargan de *Hugging Face Hub* en el primer arranque de cada contenedor y se conservan en un volumen persistente para no repetir la descarga.

Como el objetivo tras concluir la fase de entrenamiento es poder continuar la redacción de la memoria en cualquier dispositivo sin necesidad de GPU, el repositorio se distribuye también en un paquete portable reducido (código, memoria, demostraciones y los resultados intermedios del análisis) que excluye deliberadamente los conjuntos de datos crudos, los *checkpoints* de entrenamiento y la caché de modelos (del orden de 90 GB en conjunto y prescindibles para este fin), documentando en un fichero de nivel superior cómo y por qué se han omitido, y cómo recuperarlos si en el futuro fuese necesario reanudar el entrenamiento.